追加学習における既存知識への干渉を考慮した影響関数に基づくデータ合成

名古屋大学 竹内・田地研 B4 高木 優斗

本日の内容

1 はじめに

2 基礎事項

3 提案手法

4 計算機実験

5 まとめ

AIの社会実装の現状と課題

- AIの社会実装が急速に進展
  - 自動運転は最も顕著な例の一つ
- しかし，最大の課題は“安全性”
  - どんな状況でも安全な判断が下せるか？

レベル4 完全自動運転のロボタクシー

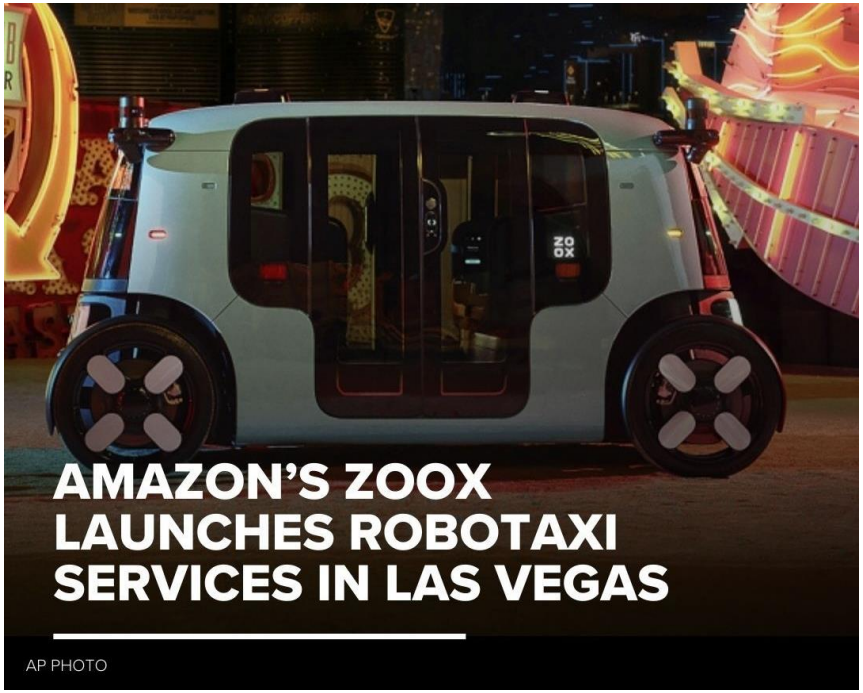

Source: ABC7 News / Facebook

自動運転におけるロングテール問題

稀にしか起こらないため，データ不足により学習が極めて困難な運転状況が存在する
この領域での安全性をどう担保するかが，完全自動運転実現のための最重要課題となっている

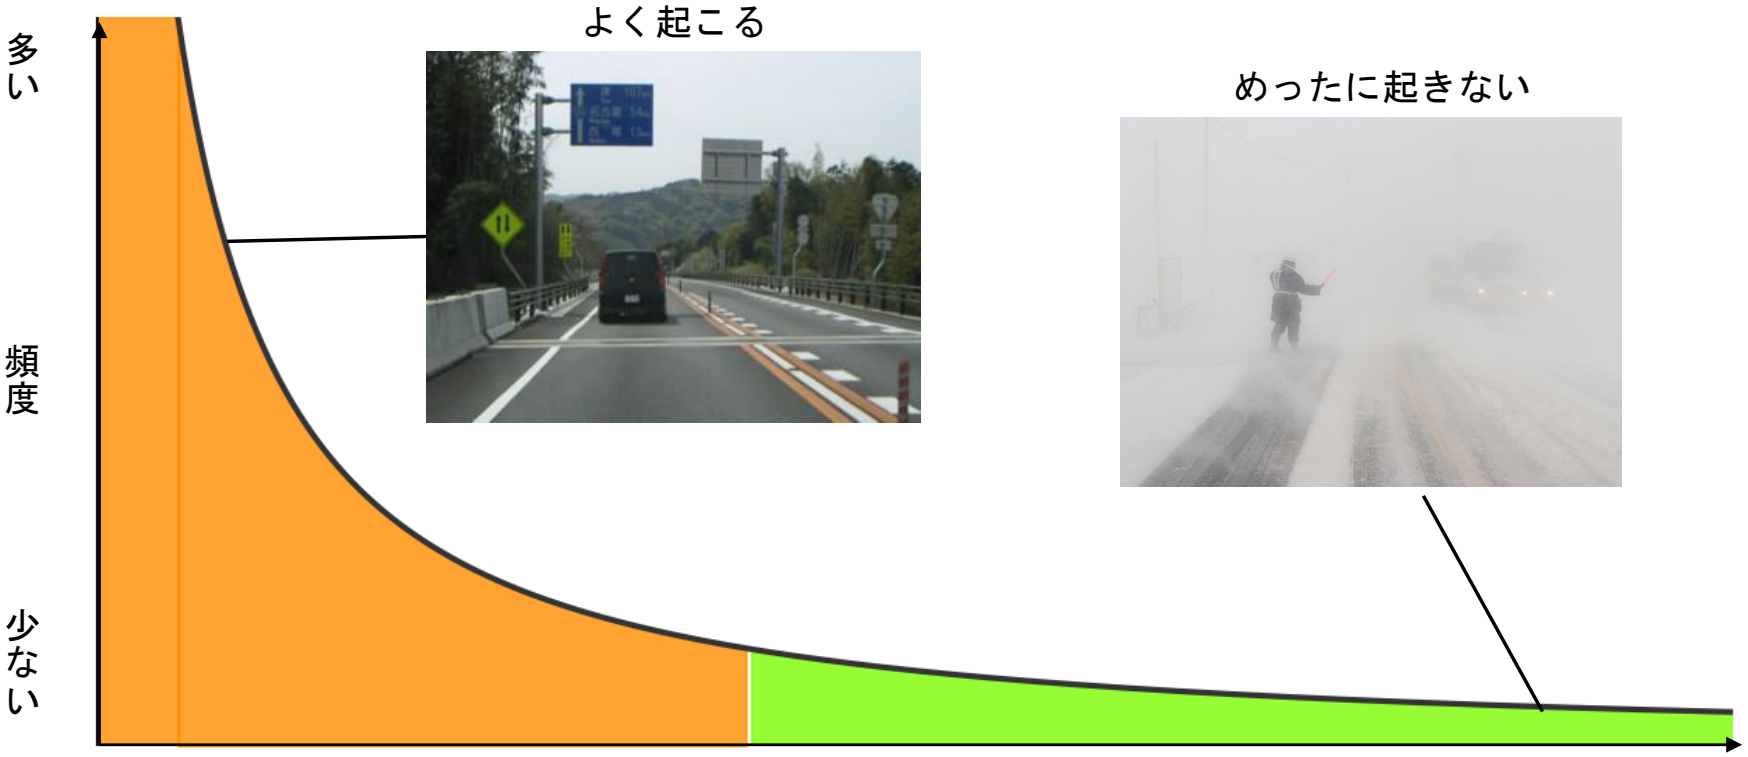

ロングテール問題への対策

実データで学習可能

実データが十分に得られない

安全性のため，このような
エッジケースも学習したい

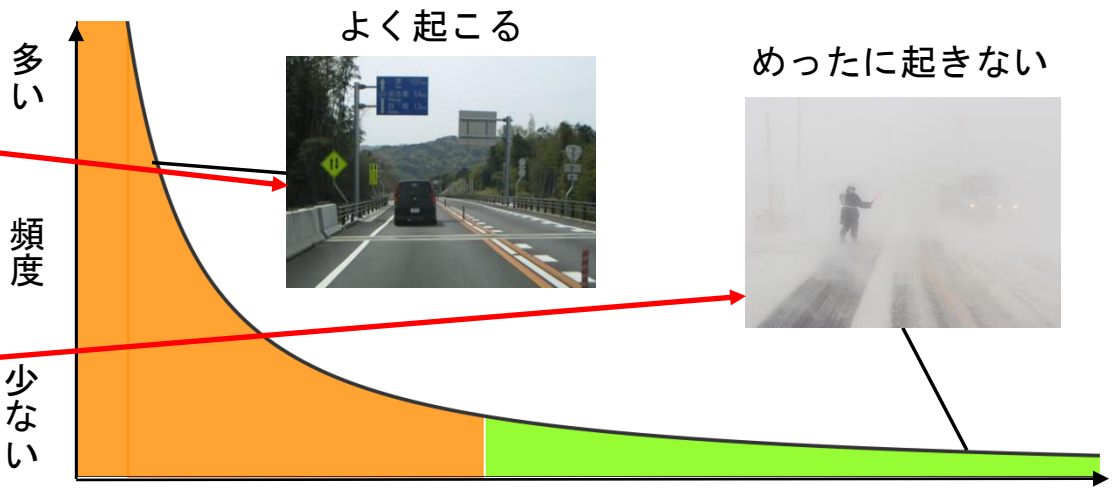

人工的な合成データでデータ拡張

データ拡張における課題

既存の重要知識に対する破滅的干渉を起こしてしまう

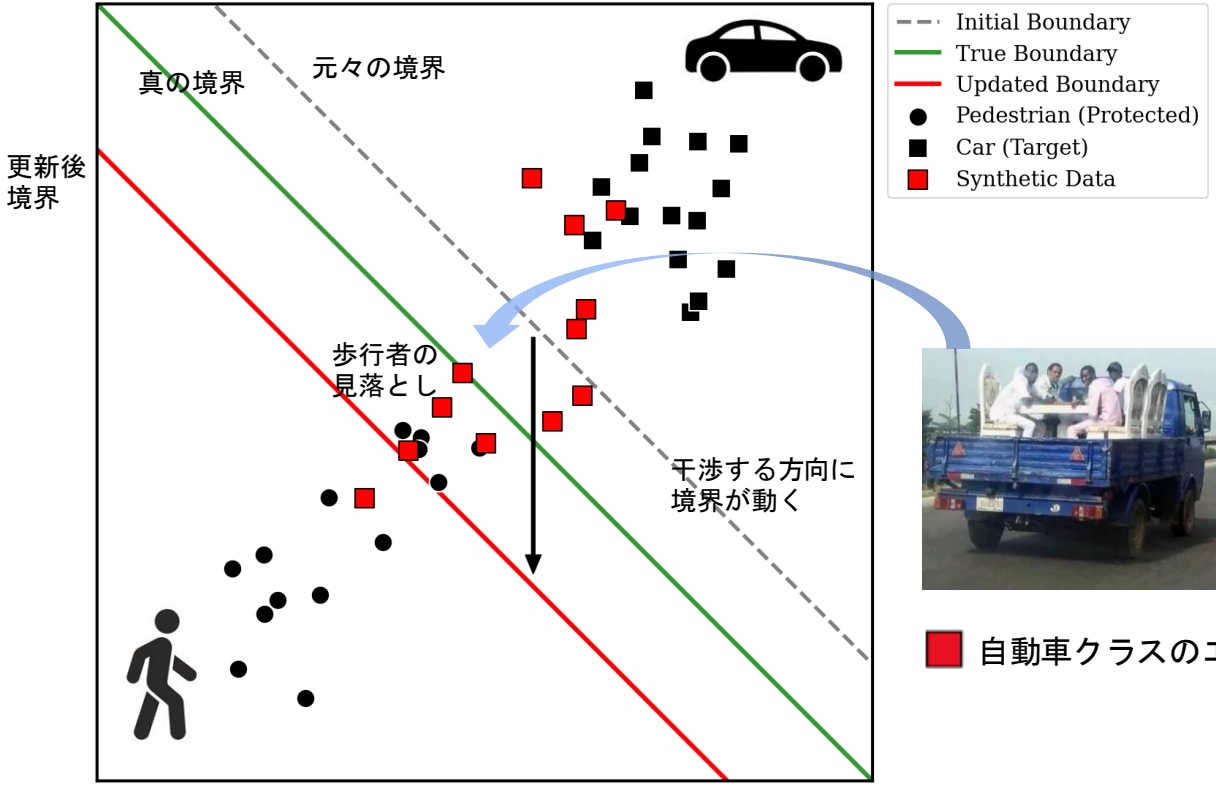

自動車クラスのエッジケース

本研究の目的

重要な既存知識に対して干渉を起こさないような合成データを生成する

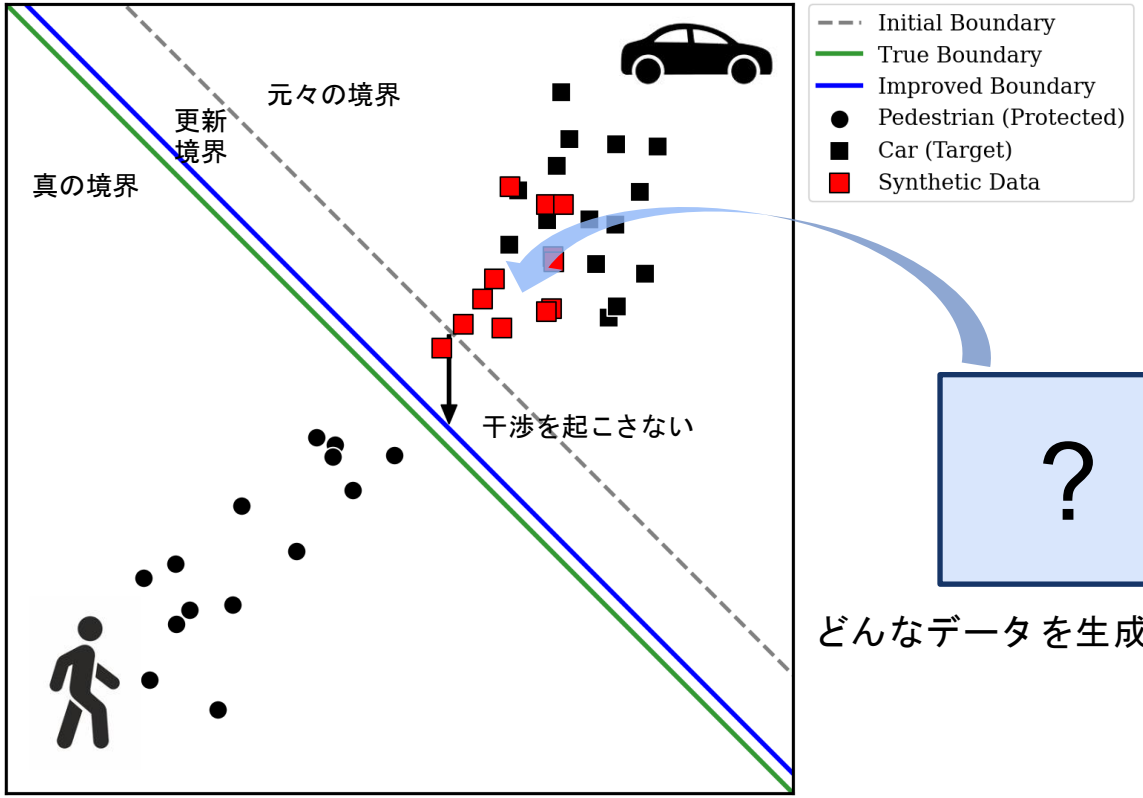

?

どんなデータを生成すれば良いか?

問題設定

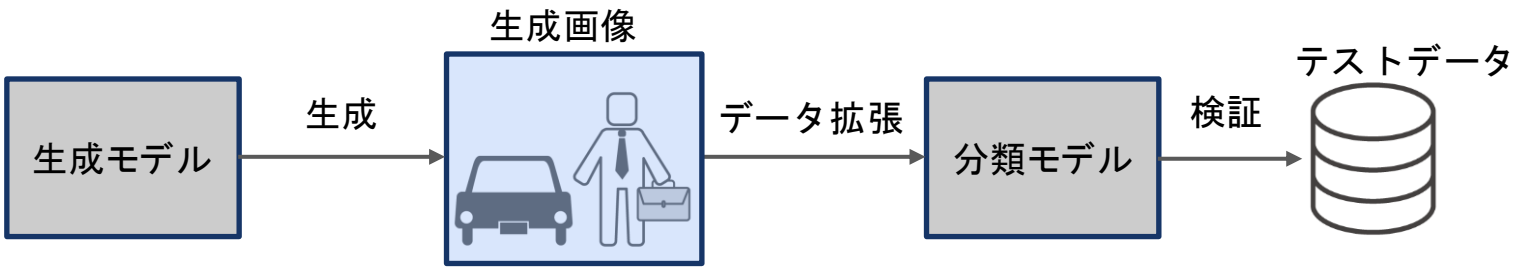

問題:
あるクラスのデータを合成データで拡張したいが，他クラスの忘却を起こしたくない
このとき，どのようなデータ生成手法が考えられるか？

本研究の貢献:
データの影響を測定する影響関数を用いて，他クラスへの悪影響を最小化するように
生成モデルを誘導することで，忘却の緩和に挑んだ

本日の内容

1 はじめに

2 基礎事項

3 提案手法

4 計算機実験

5 まとめ

基礎技術：現代の生成モデル

画像や動画の生成は拡散モデルが主流

Stable Diffusion (画像)

Stability AI, "Stable Diffusion 3: Research Paper", 2024.

Sora (動画)

OpenAI (2024), Sora, arXiv:2402.17177

本研究でも拡散モデルを取り扱う

DDPM: 本研究で扱う拡散モデル

Denoising Diffusion Probabilistic Model (DDPM) Ho et al. 2020

順拡散過程(←): 画像に少しずつノイズを加えて壊していく過程
逆拡散過程(→): ノイズを少しずつ除去して復元していく過程

加えられたノイズを予測しながら復元していくことで最終的に自然な画像になる

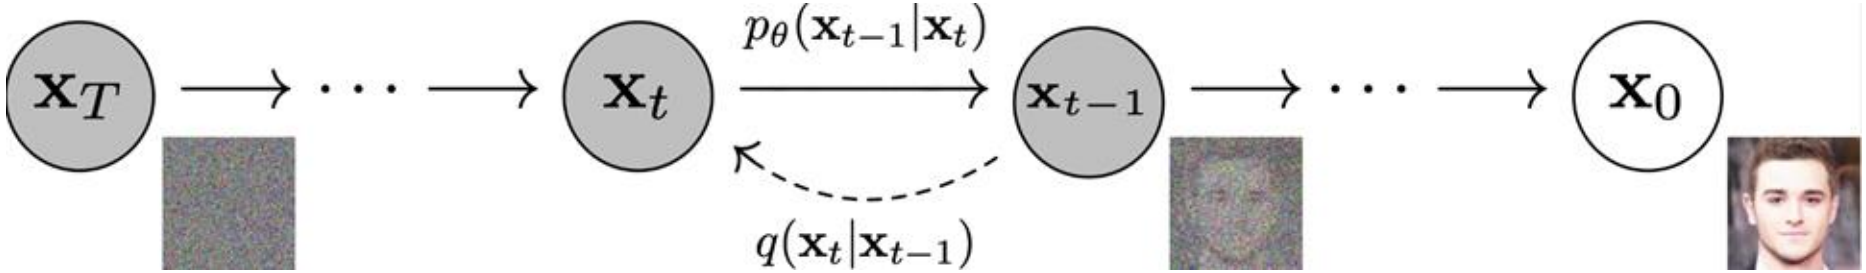

影響関数: データが及ぼす影響を数値化する関数

Koh and Liang 2017

データxをモデルに追加学習する前に，テストデータへの損失がどう変わるかを予測したい

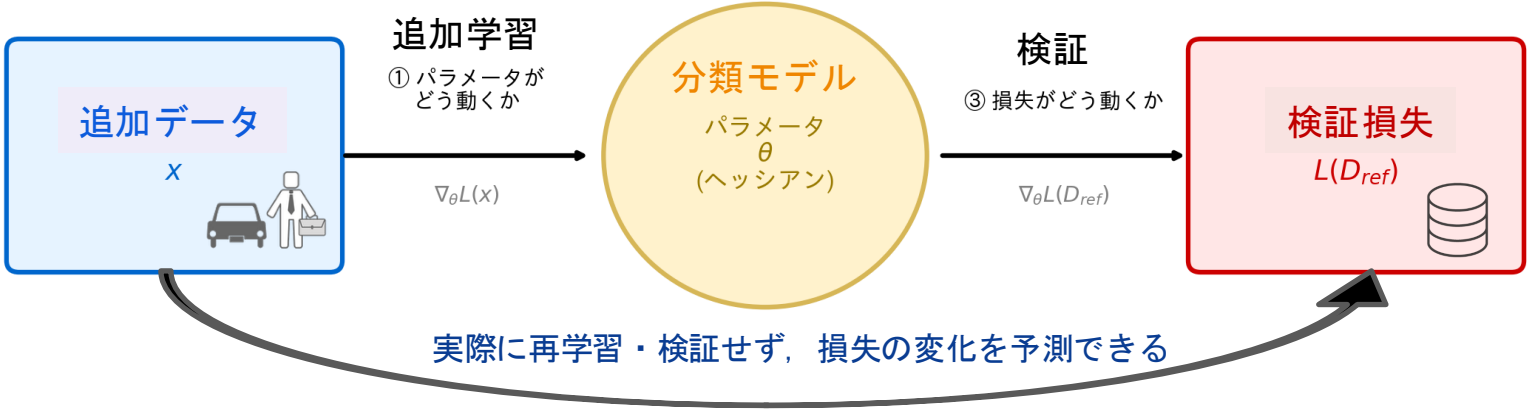

影響関数：データ追加による損失変化を，ヘシアンを用いて一次近似したもの

$$I(x, D_{ref}) \approx -\ \nabla_\theta L(D_{ref})^\top \cdot H_\theta^{-1} \cdot \nabla_\theta L(x)$$

パラメータが
どう動くか

ヘシアン

損失が
どう動くか

本日の内容

1 はじめに

2 基礎事項

3 提案手法

4 計算機実験

5 まとめ

目的と課題

クラスA: 合成データで拡張したいクラス
クラスB: 精度を低下させずに守りたいクラス
目的: クラスAの正解率を改善し，クラスBの正解率を悪化させない画像を生成する

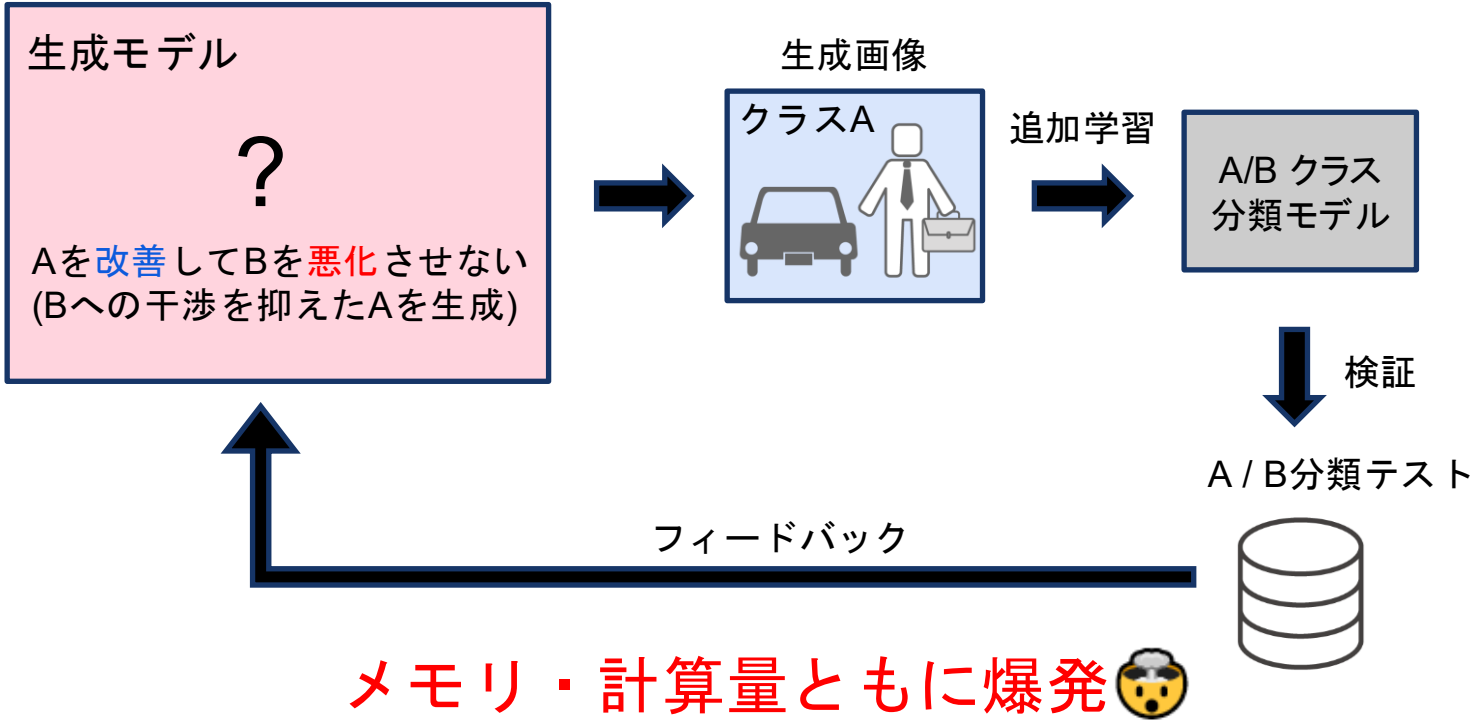

メモリ・計算量ともに爆発

提案手法の概要

クラスA: 合成データで拡張したいクラス
クラスB: 精度を低下させずに守りたいクラス
目的: クラスAの正解率を改善し，クラスBの正解率を悪化させない画像を生成する

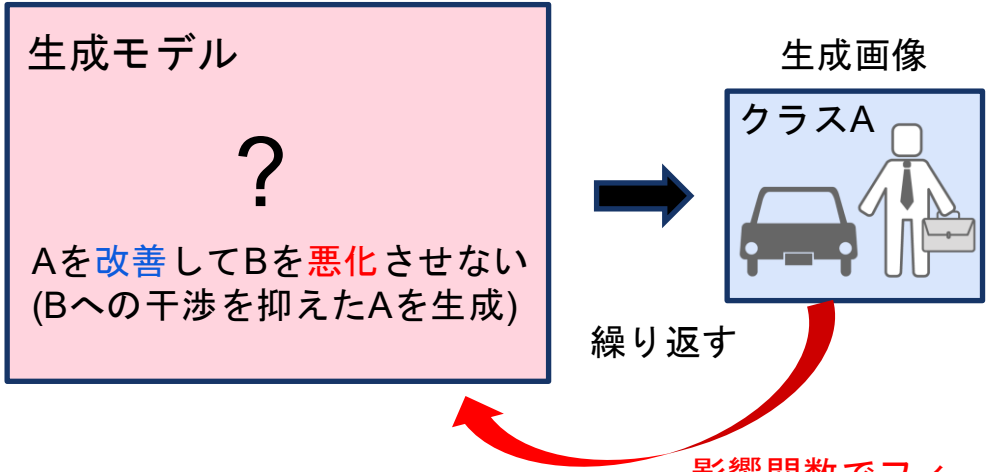

・Aを改善するにはこういう画像であるべき
・Bを悪化させないためには，こういう画像であるべき

現実的な計算量でフィードバックを得られる

生成モデル(DDPM)の内部の仕組み

影響関数からのフィードバック $I(x, D_{ref})$を基に拡散モデルを誘導する

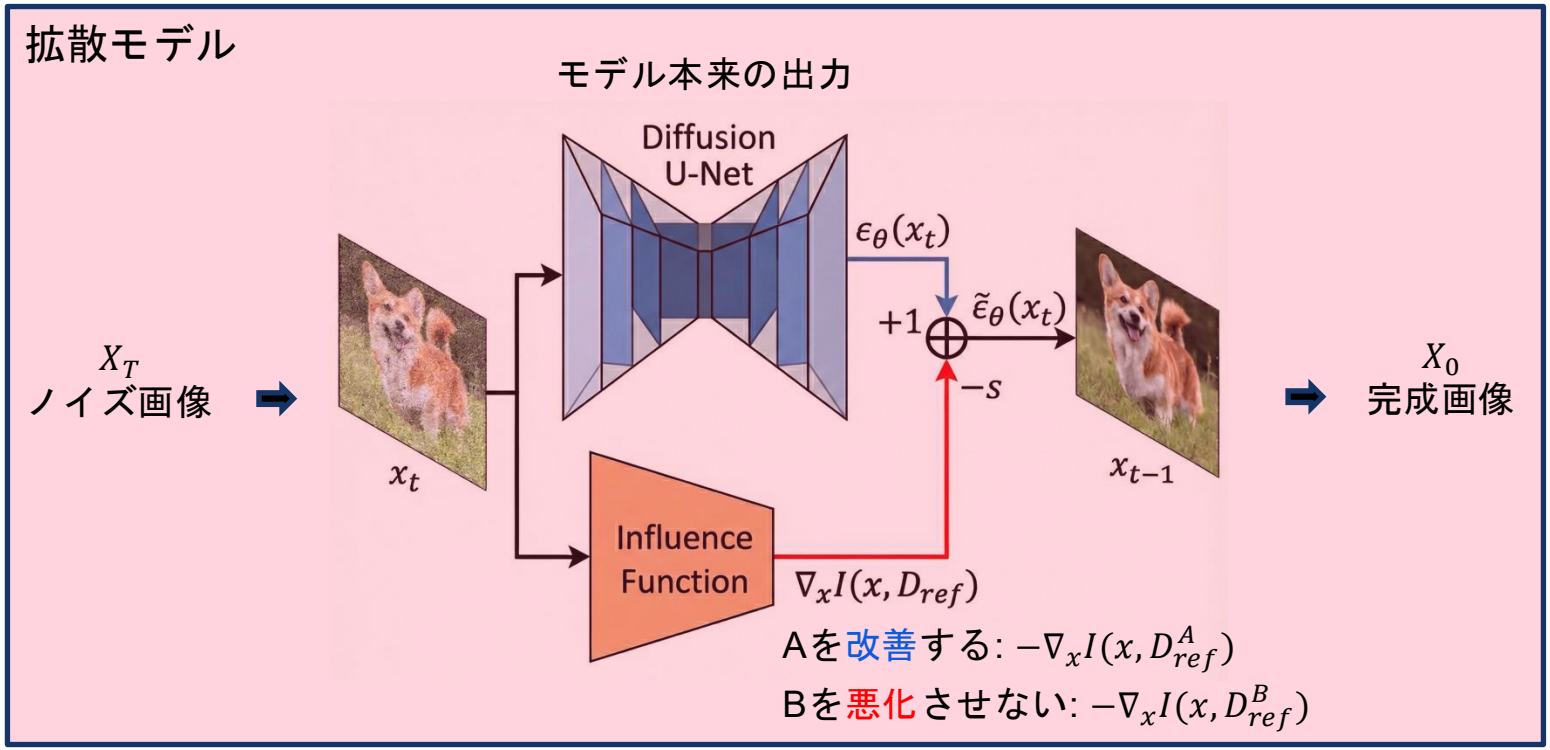

Classifier Guidanceの仕組みを流用 [Dhariwal & Nichol, NeurIPS 2021]

Appendix: 干渉を抑制する生成プロセス

提案手法の流れ

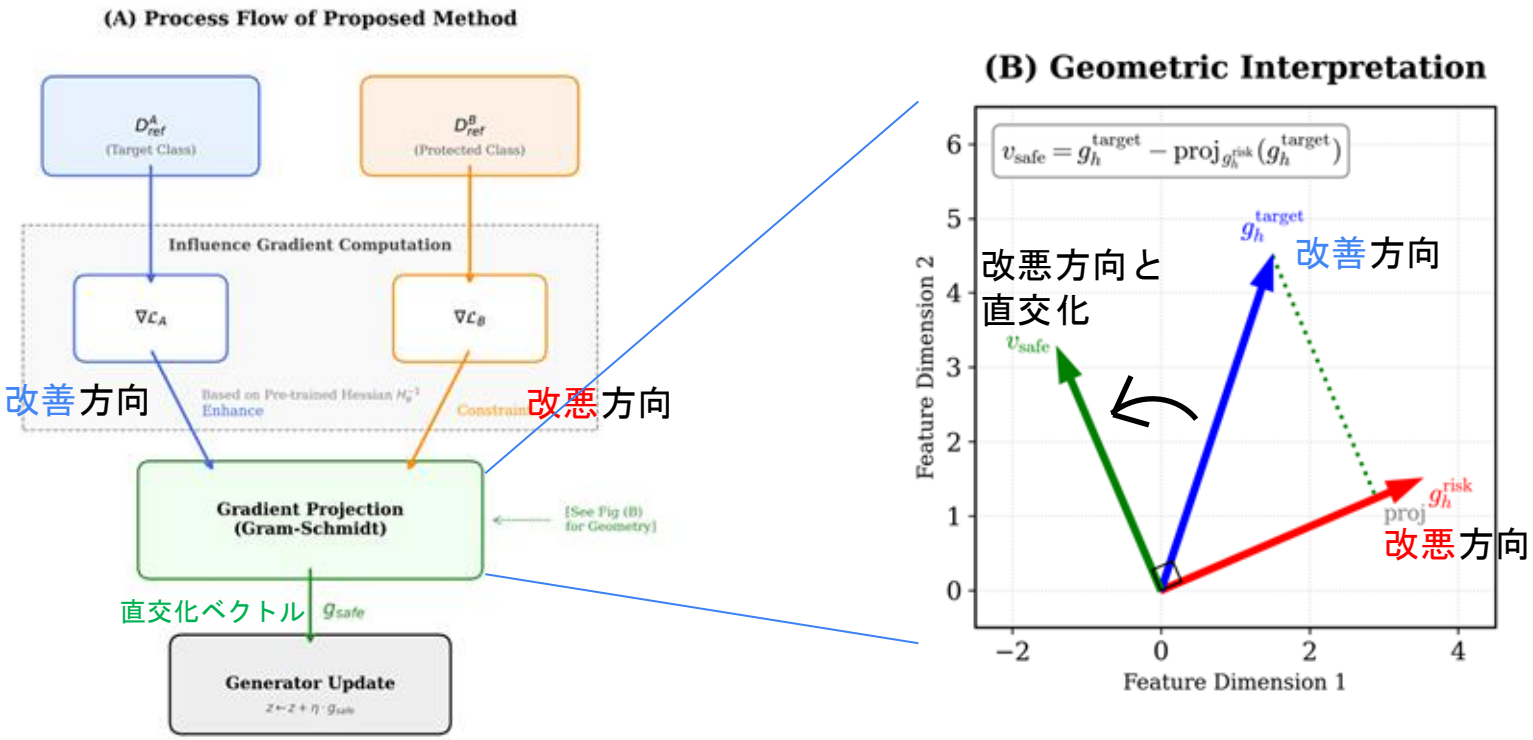

本日の内容

1 はじめに

2 基礎事項

3 提案手法

4 計算機実験

5 まとめ

実験設定：CIFAR-10を用いた検証

設定: 特徴が類似し干渉が発生しやすい「鹿 vs 馬」で実施
目的: 馬の認識精度を落とさないような鹿の画像を生成する

生成モデル：DDPM (32*32 ピクセル空間で拡散，データセットで訓練済)

分類モデル：特徴抽出器 (256次元，固定) + ロジスティック回帰(追加学習対象)

VS

Appendix: 影響関数による損失予測の妥当性

実験内容:

初期データセットに含まれないデータプールからランダムに200枚のクラスA画像を選出し，影響関数によるクラスBへの悪影響の予測値と実測値を比較

結果:

理論値と実測値の相関係数は0.954であり，高精度で予測ができている

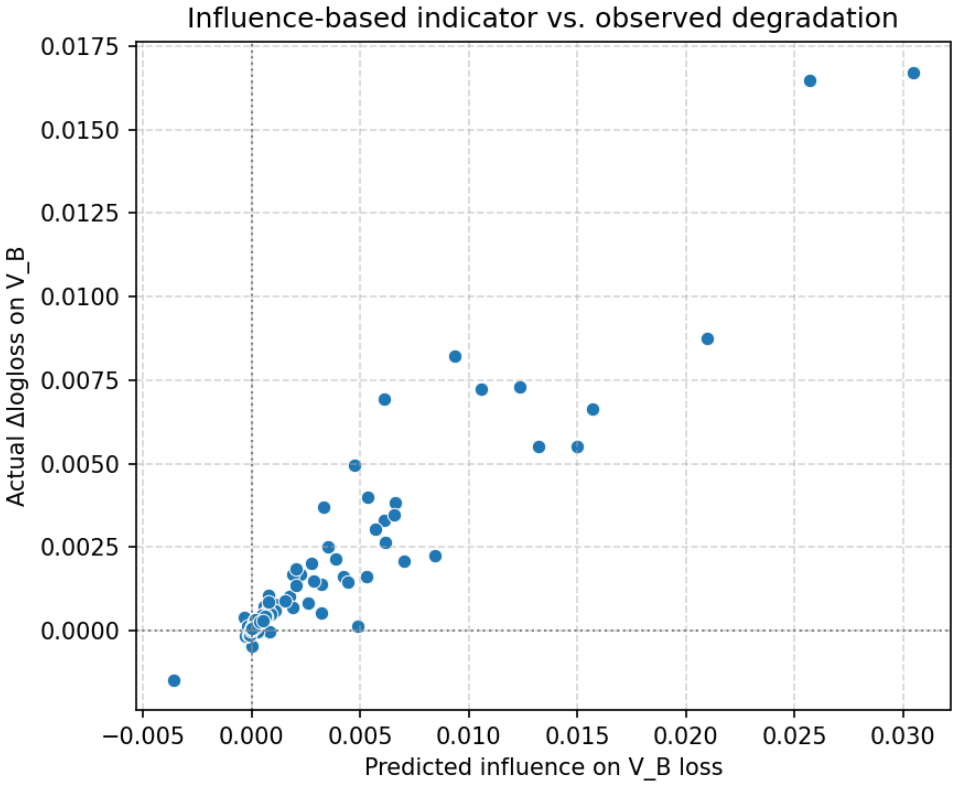

検証1: 影響スコアと画像の定性的観察

影響関数に基づく，馬のクラスへの干渉リスクの高さと画像特徴の関係

・干渉スコアが上位9枚の画像 : **馬のクラスと混同しやすく**曖昧
・干渉スコアが下位9枚の画像: **鹿のクラスを象徴する特徴 (雪の背景や角など)** が顕著

高スコアであった鹿画像

低スコアであった鹿画像

検証2: 誘導手法による追加学習結果の比較

設定: 2種類の誘導ベクトルで生成した鹿の画像50枚を分類モデルに追加学習する
目的: 鹿の画像を追加しても，馬のデータの認識精度が落ちていないかを確認

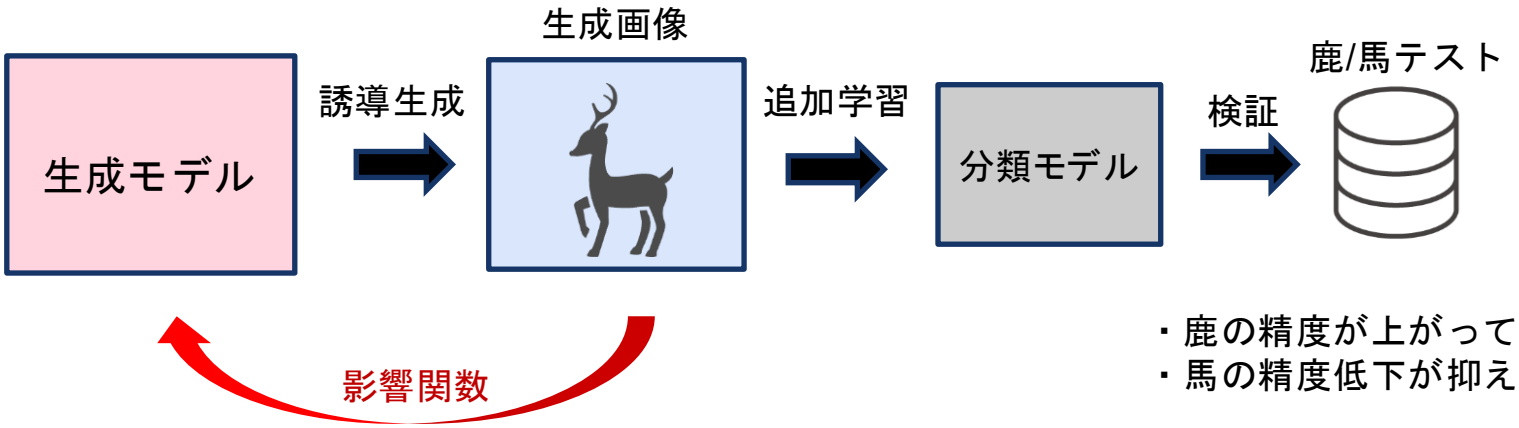

・鹿の精度が上がってるか？
・馬の精度低下が抑えられるか？

鹿クラスを改善する誘導g_A

馬クラスの悪化を抑える誘導$-g_B$

検証2: 誘導手法による追加学習結果の比較

結果をまとめる

- 鹿クラスの正解率を最も上げたのはg_Aによる誘導ではなく，無条件で生成した画像であった
- 一方，馬クラスの正解率の低下幅を最も抑制できたのは$-g_B$による誘導生成であった
- 全体として，$-g_B$による誘導は，実データよりも全体精度が良い結果となった
- g_Aによる誘導の結果が想定外であったため，直交化ベクトルによる誘導手法も再考する必要がある

注: 追加するのは鹿の画像のみ

	初期値	実データ画像 50枚追加後	誘導なし生成 50枚追加後	$-g_B$で生成誘導 (馬クラスの悪化抑制)	g_Aで生成誘導 (鹿クラスの改善)
鹿クラス正解率	90.0%	+ 5.5%	+ 5.9%	+ 4.9%	+ 5.2%
馬クラス正解率	92.0%	- 5.6%	- 6.3%	- 4.3%	- 5.2%
全体正解率	91.0%	+ 0%	- 0.2%	+ 0.3%	+ 0%

本日の内容

1. はじめに
2. 基礎事項
3. 提案手法
4. 計算機実験
5. まとめ

まとめ

- 結果
  - 干渉を最小化して生成したデータは，保護したいクラスの悪化抑制に一定の効果がみられ，また実データよりも全体精度が向上した
  - しかし，鹿クラスの精度を向上させるように誘導しても，鹿クラスの正解率向上効果は低下した
- 考察
  - 誘導によって，生成データの多様性が失われてしまったことが原因と考えられる
- 今後の展望
  - 個々のデータを独立最適化するのではなく，追加するデータ全体を一度に集合最適化する

Appendix: 影響関数に基づく「干渉」の定義

干渉: クラスAを改善しようとすると，同時にクラスBを悪化させてしまう

クラスA のデータx'を追加学習するとしたとき，
クラスAの改善方向は，

$$g_A = -\nabla_{x'} I(x', D_{ref}^A)$$

クラスBの改悪方向は，

$$g_B = +\nabla_{x'} I(x', D_{ref}^B)$$

. このとき内積が

$$g_A \cdot g_B > 0$$

で同じ向きを向いていたら干渉と定義する

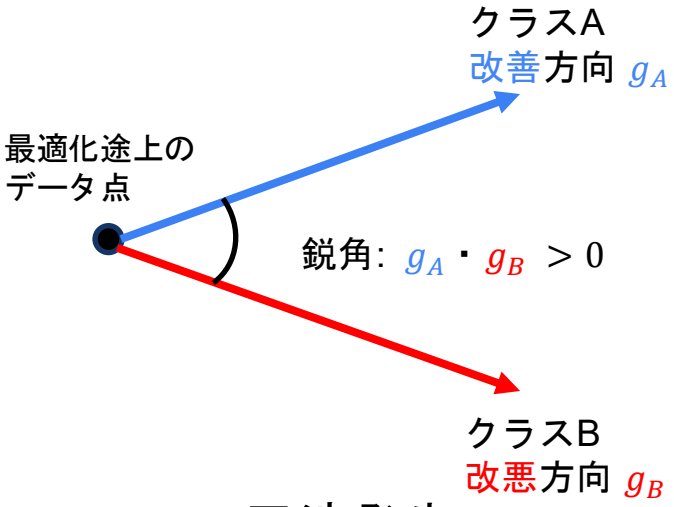

干渉発生

どのように干渉を回避するか

Appendix: 干渉を抑制する生成プロセス

提案手法の流れ

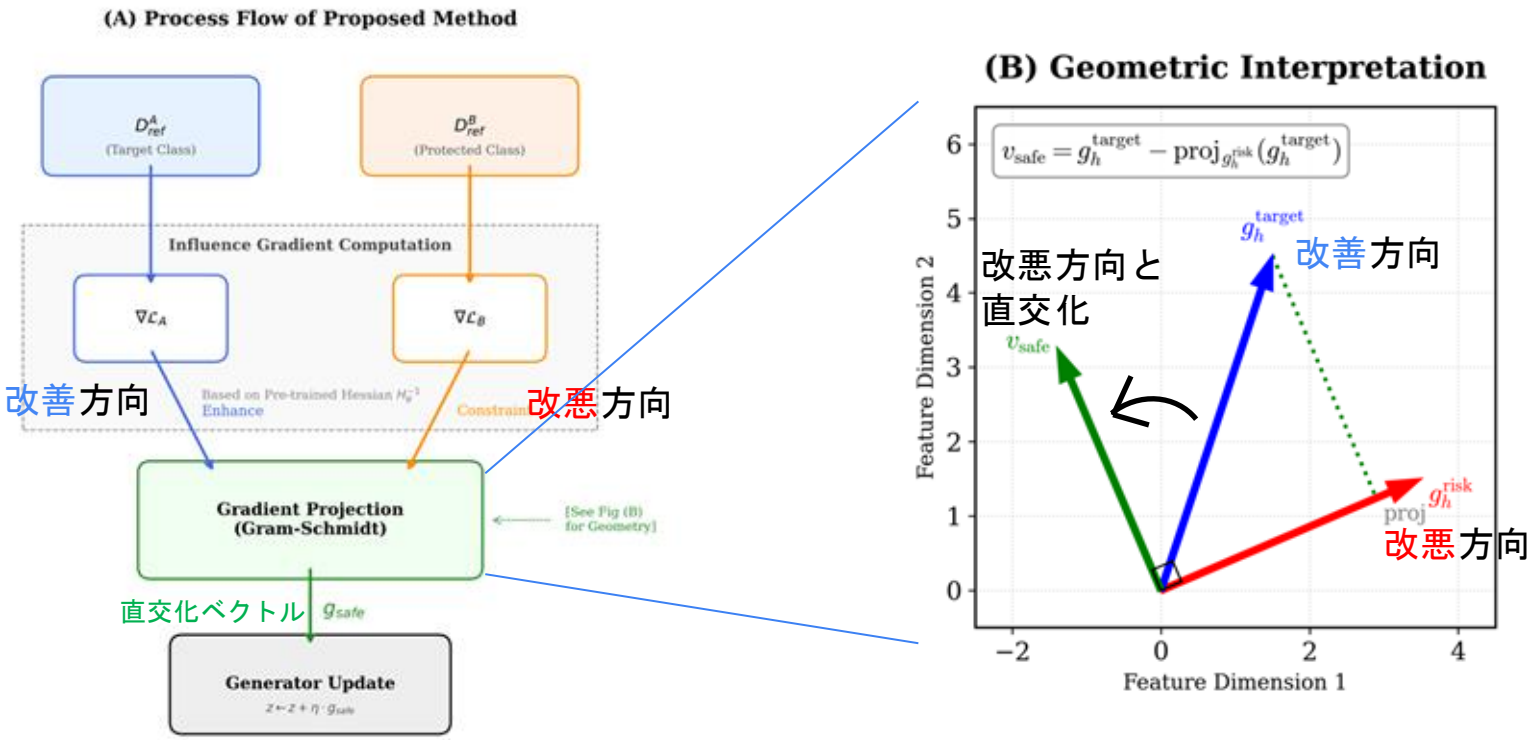

Appendix: 逆拡散過程におけるサンプリング軌道の制御

導出した誘導ベクトル (→) で生成モデルを誘導

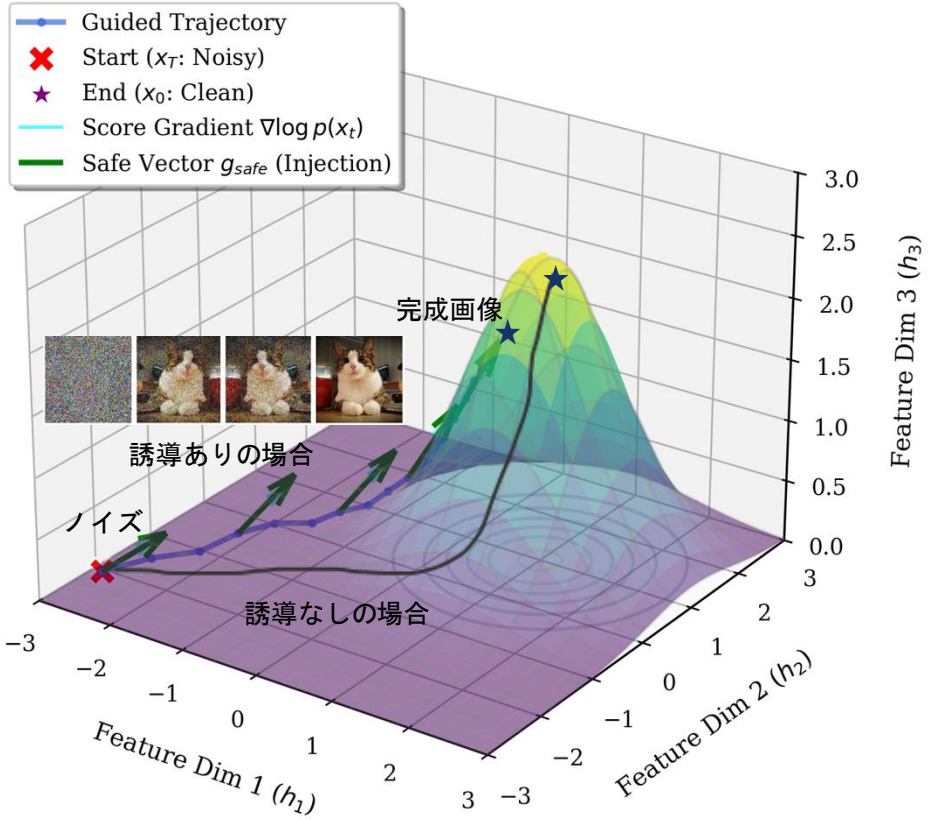

Appendix: 影響関数による損失予測の妥当性

実験内容:

初期データセットに含まれないデータプールからランダムに200枚のクラスA画像を選出し，影響関数によるクラスBへの悪影響の予測値と実測値を比較

結果:

理論値と実測値の相関係数は0.954であり，高精度で予測ができている

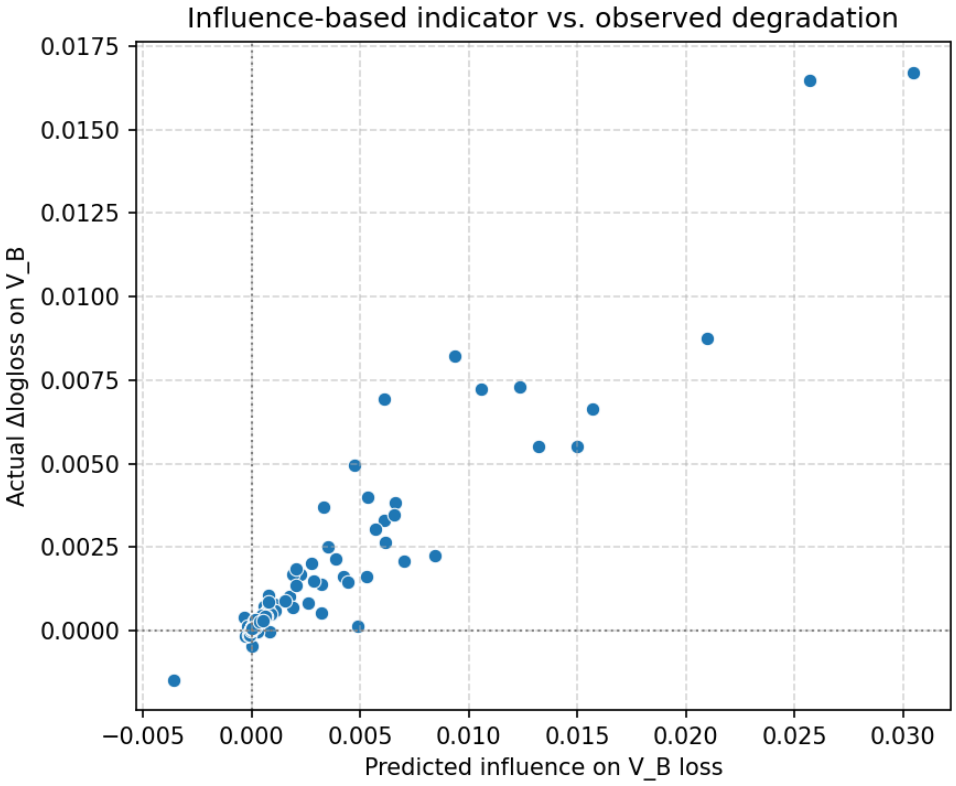

Appendix: 直交化ベクトルによる誘導の結果

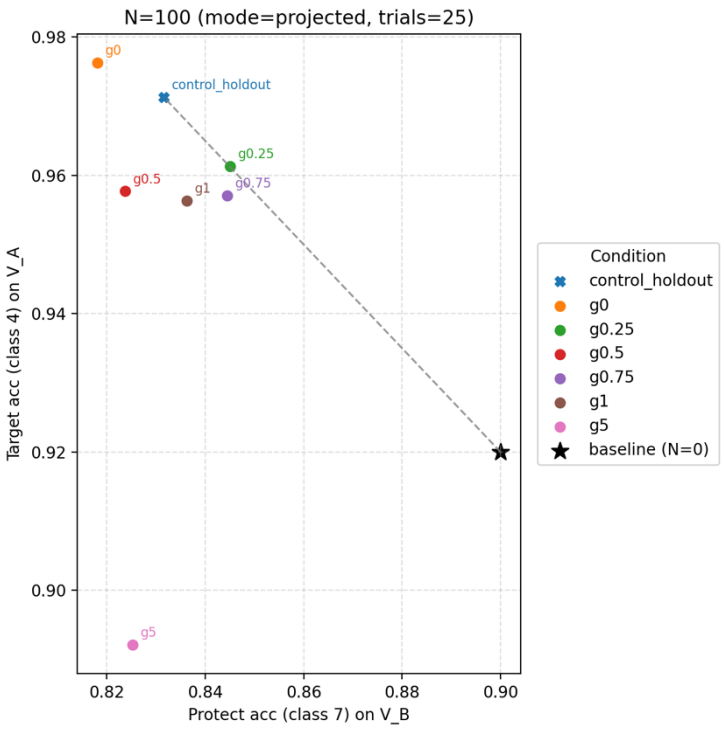

鹿の認識精度を高め，
かつ馬の認識精度を落とさない誘導