Influence-Guided Data Synthesis for Safe Incrimental Learning

Yuto Takagi

Takeuchi-Taji Lab

December 16, 2025

背景：合成データによるモデル更新とそのリスク

合成データによるインクリメンタル更新

Diffusion 等の生成モデルの発展により，**合成データを用いたモデル更新（Model Patching / Incremental Update）**は，実運用において一般的になりつつある。

見落とされがちな問題

合成データは，

- 既存の決定境界を歪める
- 重要クラスの **False Negative** を増加させる

など，**既存機能を破壊するリスク**を持つ。

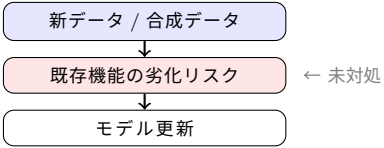

課題：
合成データを「入れる前」に，
その安全性をどう保証するか？

実運用で「データが十分に使えない」更新シナリオ

前提：実環境では，モデル更新時に**過去データを十分に保持・再利用できない**状況が多い。

Scenario A: Edge / On-device Update

- 車載器・ロボット単体での即応的な適応
- 過去データは保存不可（容量・プライバシー）

少量 or Data-Free 更新

Scenario B: Cloud-side Sustainable Update

- 継続的なモデル改善が必要
- 全履歴データの保持は非現実的（コスト・規制）

過去分布が疎な更新

重要な共通点

どちらのシナリオでも，**モデル更新は「不完全なデータ分布」上で行われる。**
⇒ 合成データの影響が，直接モデルの信頼性に跳ね返る。

課題設定：合成データ更新における安全性保証

問題

合成データを用いて特定クラスを強化すると，**既存の重要クラスの見逃し（False Negative）が増加**することがある。

- 全体精度の向上だけでは不十分
- 安全クリティカルなクラスの劣化は許容不可
- **学習後の評価では遅い**

本研究の視点：
合成データを**学習に入れる前**に，その**安全性を定量的に検査する**

本研究では，影響関数に基づく **安全性スコア** を定義し，合成データ生成・選別プロセスに一貫して組み込む。

背景と課題：追加学習のジレンマ

現状の課題認識

運用中の AI モデルに対し、特定クラス（例：Class A）を強化するために合成データを追加学習すると、**既存の重要クラス（例：Class B）の見逃し (False Negative) が増加**してしまうことがよくある。

- **破滅的干渉**: 新しい知識が、既存の決定境界を侵食する現象
- **車載システム等の要件**:
  - 全体精度 (Accuracy) の向上だけでは不十分
  - 「以前は検出できていた歩行者が検出できなくなる」劣化は許容不可
  - 学習に追加する合成データは「安全」である必要がある

結論：再学習後にモデルを調整するのではなく、
追加するデータに“安全性基準”を設ける必要がある

本研究では、この安全性基準を Diffusion による画像生成段階へ一貫して適用し、
“Safe データ”のみを自動的に生成する仕組みを提案する

具体例：精度向上と見逃しの増加

1. 初期状態 (Before)

データセット（計 200 枚）

- Class A: 100 枚
- Class B: 100 枚

精度（バランス良）

- A 正解率: 90%
- B 正解率: 90%

全体精度: 90.0%

$\Longrightarrow$

Class A の合成画像を 100 枚追加

2. 追加学習後 (After)

データセット（計 300 枚）

- **Class A: 200 枚**
- Class B: 100 枚

精度（多数派へ過学習）

- A 正解率: $\mathbf{98}\%$ ↑
- B 正解率: $\mathbf{86}\%$ ↓ **悪化**

全体精度: 92.0% ↑

ここでの問題点

- 全体精度は $90\% \to 92\%$ と向上しているため、一見成功に見える
- しかし、モデルは「迷ったら A と答える」ようになり、**守りたかった B の見逃し (FN) は悪化**している

提案手法：Diffusion Model による「安全なデータ」の生成

コンセプト：アクセル項とブレーキ項による生成制御

アクセル (性能向上)

目的関数：Class A の性能改善
特定クラスの recall を高めるために
有用なデータを供給する力

＋

ブレーキ (干渉抑制)

干渉スコア
既存重要クラスの
損失悪化を予測し、抑制する力

- **干渉スコア (Interference Score)**:
  影響関数に基づき、「その画像を学習させた時に、保護したいクラスの検出精度にどれだけ悪影響があるか」を数値化した指標
- **生成誘導**: 生成過程で干渉スコアを最小化するように Classifier Guidance 的手法により誘導し、**「無害かつ有用なデータ」**のみを生成する

提案手法：Safety-Aware Generative Replay

Interference Score (干渉スコア) を定義し、生成プロセスにフィードバックする。

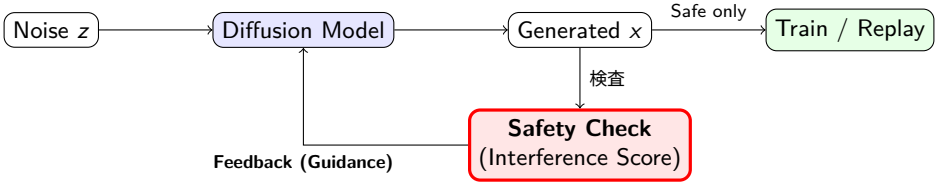

影響関数により ΔL_B (損失悪化) を予測 [cite: 11]

- **アクセル**: ターゲットクラス（A）の精度向上
- **ブレーキ**: 保護クラス（B）への**干渉（Interference）**を抑制 [cite: 27-29]

理論：影響関数による「安全性（干渉スコア）」の定量化

目的: 画像 z を追加した際、保護したいクラス B（例: 歩行者）の損失 L_B がどれだけ悪化するかを見積もりたい。

干渉スコア (Interference Score) の導出

候補画像 x_z を追加したときの、既存モデルパラメータ w への影響を一次近似で計算。

$$\Delta L_B \approx \underbrace{-(\nabla_w \ell_z)^\top}_{\text{追加データの勾配}} \cdot \underbrace{H^{-1}}_{\text{ヘシアンの逆行列}} \cdot \underbrace{g}_{\text{クラス B の勾配}}$$

- $\nabla_w \ell_z$: 追加する候補画像 z がモデルに与える勾配
- H: 既存データセットにおけるモデルのヘシアン（曲率）
- $g = \nabla_w L_B(w)$: 守りたいクラス B の損失勾配

この ΔL_B（干渉スコア）を最小化する z を生成すれば、クラス B を破壊しない。

理論：大規模モデルへの適用と計算効率

ViT 等の大規模モデルでは、パラメータ数膨大によりヘシアン H の直接計算が困難。

Last-Layer Approach と 近似計算

1. **Last-Layer Approach**:
   特徴抽出層を固定し、最終全結合層（線形層）のパラメータのみを対象に干渉を計算。
2. **K-FAC 近似**:
   ヘシアンを入力相関 A と出力勾配相関 G のクロネッカー積で近似。

$$H^{-1} \approx A^{-1} \otimes G^{-1}$$

効果:

- ViT-Base (768 次元, 1000 クラス) の場合
- 真面目な計算: 数 TB メモリ → **K-FAC 利用: 約数 MB**
- これにより、実用的な計算コストで安全性の保証が可能となる。

実験設定：MNIST における「3」と「8」の干渉

背景: 形状が似ているクラス間では干渉が起きやすい。

- **追加対象 (Class A)**: 数字の「3」
- **保護対象 (Class B)**: 数字の「8」

検証シナリオ:

1. 既存モデル（3 と 8 を各 100 枚学習済み）を用意
2. 「3」の画像を追加学習
3. 「8」の分類精度（特に見逃し）が悪化しないか検証

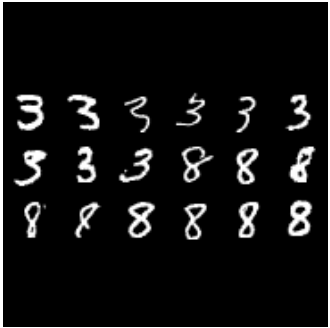

類似する「3」と「8」

検証 1：影響関数による予測精度の妥当性

問い: 導出した干渉スコアは、実際の精度悪化を正しく予測できるか？

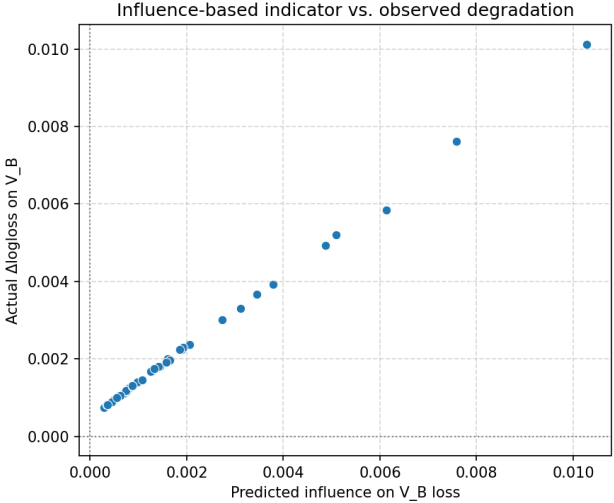

結果:

- **X 軸**: 干渉スコア（理論予測値）
- **Y 軸**: 実際の損失悪化量（再学習後の実測値）

相関係数 1.00

きれいに正の相関を示しており、
「干渉スコアを下げれば、実際の影響も抑えられる」
ことが確認された。

検証 2：生成画像データの特徴と干渉スコアの関係

問い: 高干渉スコア画像と低干渉スコア画像は、それぞれどのような特徴を持つのか？

高干渉スコア (Risky)：既存モデルを破壊するデータ

- **線が太く潰れている**
- 「8」に見間違えやすい
- これらを学習すると決定境界が歪む

低干渉スコア (Safe / Proposed)：既存モデルと共存できるデータ

- **形状が明瞭で典型的**
- 「3」と明確に判別可
- 既存の知識（8）と衝突しない

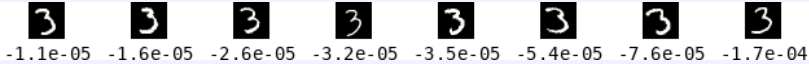

検証 3：Confusion Matrix による学習効果の可視化

問い: データセット画像のうち、高干渉スコア画像と低干渉スコア画像はどんな学習効果を及ぼすか？

Baseline (初期状態)

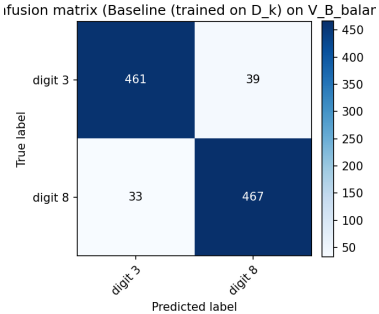

「8」の見逃し (FN): **33**

高リスク画像を追加

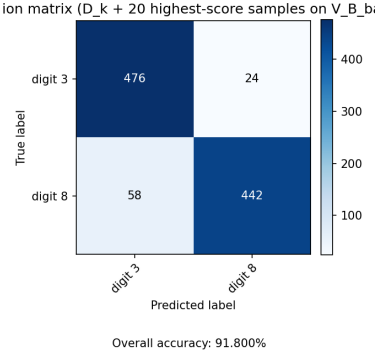

「8」の見逃し (FN): **58** ↑ 悪化

低リスク (提案) 画像を追加

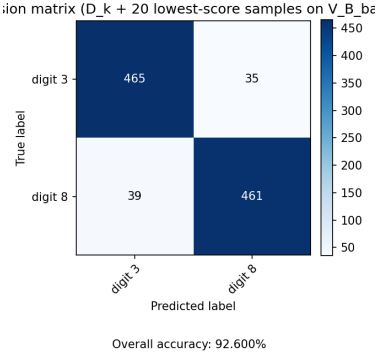

「8」の見逃し (FN): **39** → 微増

結論

実験結果: 生成誘導（Guidance）の効果

Diffusion Model の生成プロセスにおいて、干渉スコアを最小化するよう誘導（Guidance）を実施。

誘導なし (通常の生成)

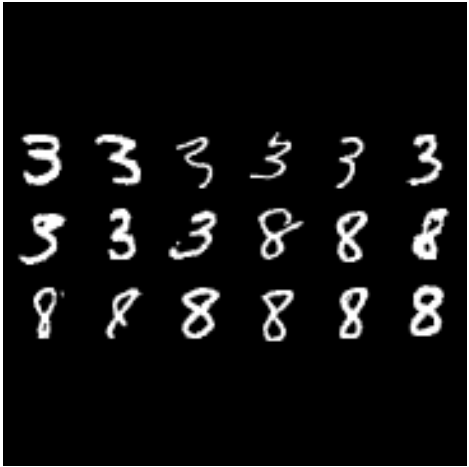

干渉スコア平均: -1.98×10^{-3}

誘導あり (Proposed)

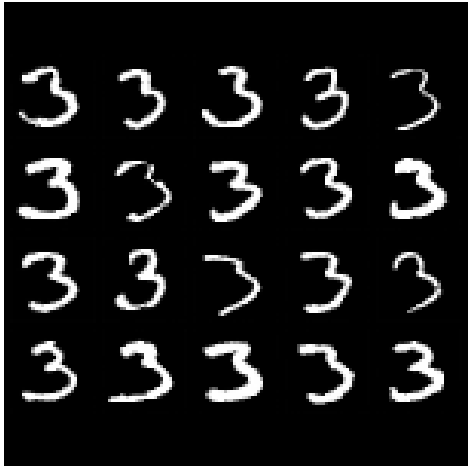

干渉スコア平均: $\mathbf{-1.49 \times 10^{-4}}$

実験結果: 生成データによる再学習の効果

干渉スコアを最小化するように誘導して生成されたデータを用いて再学習を実施

Baseline (初期状態)

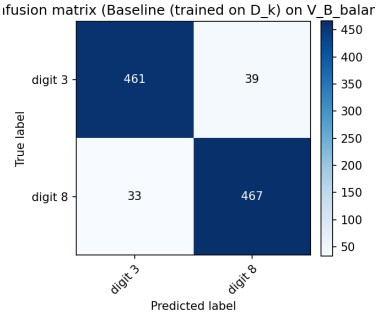

「8」の見逃し (FN): **33**

+20 ランダム生成画像

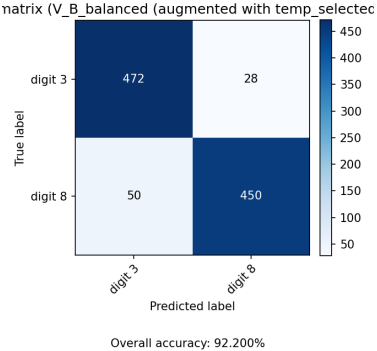

「8」の見逃し (FN): **50** ↑ 悪化

+20 誘導あり生成画像

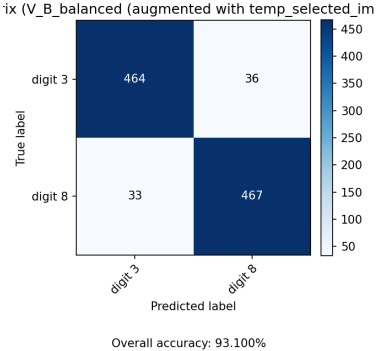

「8」の見逃し (FN): **33** → 維持
かつ全体精度↑

ViT への展開と今後の展望

Vision Transformer (ViT) への拡張

- ロジスティック回帰だけでなく、大規模モデルへの適用理論を構築中
- **Last-Layer Approach**: ViT の特徴抽出層を固定し、最終全結合層の干渉のみを計算することで、十分な精度を保ちつつ計算コストを現実的範囲に圧縮

想定ユースケース

- **コーナーケース対応**: レアな標識や障害物を追加学習したいが、基本性能（歩行者の検知など）は絶対に落とせない場面
- **データセットの品質保証 (QA)**: 数理的裏付けのあるデータ生成/選別による担保

既存機能の「安全性」を数学的に守りながら、*AI* モデルを進化させる

まとめ

- **課題**: 追加学習における「破壊的干渉（既存クラスの見逃し増加）」は、信頼性が求められる AI において致命的である。
- **提案**: 影響関数に基づいた「干渉スコア」を定義し、それをブレーキ役として Diffusion Model の生成を制御する手法を提案。
- **結果**:
  - 影響関数による理論予測と実際の影響は強く相関する。
  - 提案手法により生成された「安全なデータ」のみを追加学習することで、既存クラス（8）の性能を損なわず、ターゲットクラス（3）を強化できた。
- **今後**: ViT などの大規模モデルへの適用と、高解像度画像での実証を進める。

Appendix: 想定される質問と回答 I

Q1. 通常の追加学習 (Fine-tuning) と何が違うのか？

A:「過去データを持てない (Data-Free)」という制約が決定的な違いです。

- 通常の FT は過去データと混ぜて学習できますが、本設定ではそれができません。
- 生成データに頼らざるを得ないため、**「生成されたデータの質（有害性）」**が直接リスクになります。本研究はそのリスクを制御するものです。

Q2. Class Imbalance（データの不均衡）の問題ではないのか？

A: いいえ、量ではなく「質（干渉）」の問題です。

- データの量を調整（Re-weighting 等）しても、**決定境界を侵食する「有害なサンプル」**が混ざっていれば、境界が歪み性能は劣化します。
- 本研究は、量の調整以前に、サンプル単位で**「無害なデータを選別する」**手法であり、不均衡対策とは直交する概念です。

Appendix: 想定される質問と回答 II

Q3. 想定される具体的なユースケースは？

A: 運用中のモデルへの「パッチ当て (Model Patching)」です。

- 例：自動運転車に「特定のレアな標識」だけを追加で覚えさせたい場合。
- 全データを再学習するコストやデータ保持のリスクを避けつつ、**既存の歩行者検知などの重要機能は絶対に劣化させない**、高い信頼性が求められる場面を想定しています。

Q4. 影響関数の計算コストは重すぎないか？

A: Last-Layer Approach と近似計算で解決しています。

- ViT 等の特徴抽出層は固定し、最終層のみ計算対象とすることで次元を削減しています。
- 加えて K-FAC 近似を用いることで、現実的な計算時間・メモリ量で実行可能です。

Discussion: なぜ「データの重み付け」では解決できないのか？

Q. 生成せずに、Loss の重み付け (Re-weighting) で対処できないか？

A. 不可能です。重み付けを行う「対象（過去データ）」が存在しません。

1. 過去データへの重み付け

Past Data
(Class B)

× **Deleted / Inaccessible**

理由: プライバシー・容量制約により過去データは保持していない 。
⇒ **存在しないデータに重みは付けられない。**

2. 新データのみ重み付け

New Data
(Class A)

$\times 100$

理由: 新タスクへの過学習が加速するだけである。
⇒ **既存クラス (B) の忘却 (Catastrophic Forgetting) が悪化する 。**

結論: 生成 (Generative Replay) は必須

過去データがない以上、**「過去を代替するデータ」を生成することは必須条件**である。
本研究は、その必須である生成プロセスに「安全性」を付与するものである。

Discussion: 重みづけの数理的限界と生成の必然性

反論の核心：なぜ「重みづけ」では安全性を保証できないのか？

重みづけ (Re-weighting) は、学習ダイナミクスを**「観測点の凸包 (Convex Hull)」**内に拘束してしまう。

× Re-weighting の限界

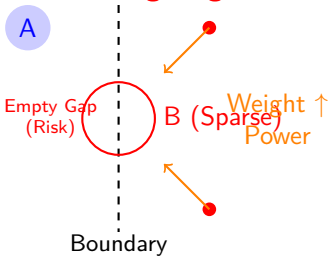

- 点の寄与を変えるだけで、**点は増えない**。
- **「点の無い空白領域」**の境界は制御不能。
- 安全性が破綻するのは、まさにこの**未観測の境界**

○ Generative Replay (Proposed)

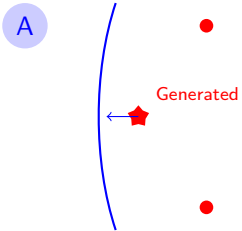

- **Functional Interpolation**:
- 真の分布でなくとも、境界決定に必要な**「構造」を補間**する点を配置。
- これにより、未観測領域の決定境界を物理的に拘

Discussion: プロセス上の安全性比較

本質的な違い： 重みづけは「祈り (Optimization)」、提案手法は「検査 (Audit)」。

Re-weighting (Reactive)

学習が終わるまで結果が分からない

重みを調整して学習を実行し、テストデータで失敗して初めて「重みが足りなかった」「データが足りなかった」と気づく。

$\Rightarrow$ **事故が起きてから対処**

Proposal (Proactive)

学習 前 にリスクを排除可能

生成されたサンプル z に対して干渉スコア $\Delta L_B(z)$ を計算することで、モデルに入れる前に**「これは危険だ」と検知・破棄**できる。

$\Rightarrow$ **事故を未然に防ぐ (QA)**

Discussion: 重みづけの数理的限界と生成の必然性

反論の核心：なぜ「重みづけ」では安全性を保証できないのか？

重みづけ (Re-weighting) は、学習ダイナミクスを**「観測点の凸包 (Convex Hull)」**内に拘束してしまう。

× Re-weighting の限界

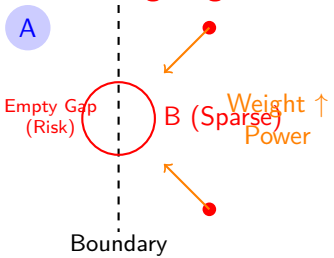

- 点の寄与を変えるだけで、**点は増えない**。
- **「点の無い空白領域」**の境界は制御不能。
- 安全性が破綻するのは、まさにこの**未観測の境界**

○ Generative Replay (Proposed)

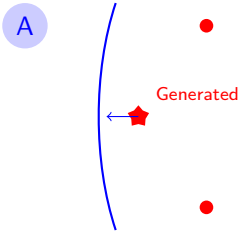

- **Functional Interpolation**:
- 真の分布でなくとも、境界決定に必要な**「構造」を補間**する点を配置。
- これにより、未観測領域の決定境界を物理的に拘

Discussion: プロセス上の安全性比較

本質的な違い： 重みづけは「祈り (Optimization)」、提案手法は「検査 (Audit)」。

Re-weighting (Reactive)

学習が終わるまで結果が分からない

重みを調整して学習を実行し、テストデータで失敗して初めて「重みが足りなかった」「データが足りなかった」と気づく。

$\Rightarrow$ **事故が起きてから対処**

Proposal (Proactive)

学習 前 にリスクを排除可能

生成されたサンプル z に対して干渉スコア $\Delta L_B(z)$ を計算することで、モデルに入れる前に**「これは危険だ」と検知・破棄**できる。

$\Rightarrow$ **事故を未然に防ぐ (QA)**