追加学習のための画像生成

Yuto Takagi

December 9, 2025

これまでの流れ

流れ

- 画像分類モデルの worst-case な場合の精度向上を保証する問題設定
- 具体的には、候補画像を追加したときに分類精度がどう変わるかを保証する
- しかし、改善量の下界の定式化が困難であるので、改悪量の上界を最小化する問題に変換
- 赤羽さんの Bound-Based Approach を基に、Worsen Upper Bound (WUB) を導出
- ロジスティック回帰における WUB 計算方法を実装 / 検証し、さらに生成を誘導してみた
- しかし、WUB は特定クラス間での精度損失の上界としては機能しないことに気づき、絶望 (2 クラス分類では、クラス A の画像を追加したときの全体精度の悪化 = クラス B の損失の悪化となるため)
- クラス別の精度悪化量指標を導出するための理論パートの検討を開始

内容

スライドの内容

1. 研究テーマの背景と目的
2. 問題設定
3. 方法
4. 画像生成モデルへの応用

special thanks to: 赤羽さん
worsen upper bound の定式化部分を参考にさせていただきました。感謝！

背景

すでに運用されている AI システムに、人工的に合成された画像で追加学習を行うとき、「以前できていたことができなくなること」を防止することは最重要課題。
単純に追加学習によって分類精度が上がればいいというわけではない。
特に信頼性が重視される場面では、既存モデルの、(保護したい重要な) 特定クラスの決定境界を壊さずに、モデルの識別能力を向上させることが求められる。
例) クラス A を強化するためにデータを追加学習したら、重要クラス K の見逃しが激増してしまった、など

例：精度向上と見逃しの増加

$\longrightarrow$

1. 初期状態 (Before)

データセット（計 200 枚）

- A(3): 100 枚, B(8): 100 枚

精度（バランス良）

- A 正解率: 90% (900/1000)
- B 正解率: 90% (900/1000)

全体精度: 90.0%

クラス A を 900 枚追加

2. 追加学習後 (After)

データセット（計 1100 枚）

- **A(3): 1000 枚**, B(8): 100 枚

精度（多数派へ過学習）

- A 正解率: $\mathbf{98\%(980/1000)}$ ↑
- B 正解率: $\mathbf{86\%(860/1000)}$ ↓

全体精度: 93% ↑

- 全体精度は $90.0\% \to 93\%$ と向上しているため、成功に見える。
- しかし、モデルは「迷ったら A と答える」ようになり、**守りたかった B の見逃し (FN) は悪化**している。
- **結論：**追加学習によってクラス間の干渉が発生し、特定クラスの検出性能が大幅に悪化するリスクがある。

既存手法の限界

1. 従来の不均衡学習 (Static Imbalanced Learning)

- **手法:** 重み付け (Cost-sensitive), 過サンプリング (SMOTE) 等
- **限界:**
  - 既存モデルの決定境界（学習済み知識）を考慮しない
  - 追加データの偏りによる破壊的干渉を防げない
  - データセット全体が固定された「静的」な状況を想定
  - 学習前に「危険データ」を判定できない

2. 一般的な継続学習 (Continual Learning)

- **手法:** パラメータ正則化 (EWC) 等
- **限界:**
  - **パラメータ（重み）**を拘束することで忘却を防ぐ
  - 「どのデータを学習させるべきか」というデータ選択の視点が欠如
  - 新しい知識 (A) の獲得能力（可塑性）が低下しやすい
  - FN 増加の防止というテーマは新規

本研究の位置付け

本研究の独自性: データ中心のアプローチ

追加学習で、任意のクラスの性能悪化（特に FN 増加）を未然に防ぎながら、安全に新しいデータのみを学習するためのデータ中心手法を提案する

- 決定境界が崩れないように、パラメータではなく**データそのもの**をフィルタリング/ 生成
- 特定クラスの**見逃し (False Negative)** 増加を見積り、未然に防ぐ (理想的には数学的保証)
- 昨今の Data-centric AI の潮流にも合致

本研究のテーマまとめ

- **現状**：データ拡張や追加学習は、全体の精度向上に役立つ。
- **問題提起**：追加学習では、新しいデータが既存モデルの決定境界を押し崩し、特定クラスの性能悪化（特に False Negative の増加）が潜在的に発生する。この劣化は全体精度では検出しづらく、信頼性が要求される場面では重大な問題となる。
- **既存手法の限界**：モデルの学習設定やパラメータに制約を加えるやり方ではなく、データ中心のアプローチで決定境界を保護しながら精度向上を図る方法は確立されていない。
- **提案手法**：そこで本研究では、「特定クラスの既存の決定境界を破壊しない（Do No Harm）」という制約に基づいた新しいデータ拡張/追加学習手法を提案する。
- **想定成果**：これにより、特定クラス K の FN を可能な限り増やさずに、データ拡張対象クラス A の検出精度を安全に向上させるデータを生成することが可能になる。

問題設定

問題設定

- クラス A の画像データを追加するとき、画像分類モデルの特定クラス K の分類精度悪化の上界を求め、他クラスの FN が増加しないことを保証する。また、追加学習時に他クラスの精度低下を引き起こさない画像データを生成する。

手法

方法論の全体像

- 多クラス画像分類の問題を考える。
- クラス A の画像データ (z) を追加したとき、画像分類モデルの特定クラス K の分類精度悪化の 上界を数学的に求める、or 影響関数などで近似計算する。
- この上界 or 近似計算が、実際の分類精度の損失の上界となっていることを確認。
- SD などの拡散モデルのサンプリング過程で、この指標を最小化するような画像データを生成するように誘導する。

特定クラス間の FN 損失について

目的

- クラス A の画像を生成してデータセットに追加したとき、クラス K の精度がどれだけ悪化するかを見積もる (理想的には数学的上界)。

検討している方法

- 11 月までは、勘違いで全体の精度悪化上限 (WUB) を考えていた。
- 特定クラスの WUB への理論拡張は難しそう
- 実際の損失との相関を重視するなら、影響関数が一番実用的 (深層モデルも対応可能な上、最終線形層だけを対象にすれば ViT でも十分な精度で計算が早い (last-layer 法))

影響関数によるアプローチ

- **目的**: クラス A の画像を追加したとき、クラス K の FN 増加を影響関数で見積もる
- **問題点**: クラス K の FN 増加は、0 or 1 損失で定義されるが、影響関数は滑らかな損失関数の勾配を使うため、直接的には使えない
- **方法**: クラス K の logloss(滑らか) を悪化させない方向に生成を誘導する

多クラス設定で「クラス A を増やしたいけどクラス B の FN は増やしたくない」という問題に対して，クラス B の logloss を悪化させない方向に生成を誘導するのは妥当か？

影響関数による精度悪化量推定の定式化

基準モデル k 時点でのデータセットを D_k とし、学習済みロジスティック回帰のパラメータを (w) とする（ D_k 上で最適化済み）
D_k の平均ロスの Hessian を

$$H = \nabla_w^2 \Big[\frac{1}{|D_k|} \sum_{i \in D_k} \ell(y_i, w^\top x_i) \Big] + \lambda I$$

で計算し、(H^{-1}) を使えるようにしておく評価指標の勾配（digit 8 log loss）
監視対象の VB（digit 8 だけの集合）について、平均 log-loss

$$L_B(w) = \frac{1}{|V_B|} \sum_{j \in V_B} \ell(y_j, w^\top x_j)$$

の勾配 $(g = \nabla_w L_B(w))$ を計算し、Hessian 逆行列との積
$(H^{-1}g)$ を解く（線形方程式 $(Hv = g)$ を解いて $(v = H^{-1}g)$ を得る）。
ここまでが前計算。

定式化続き

候補サンプル z の寄与
digit 3 画像 (x_z)（ラベル $(y_z = 0)$）を 1 枚 D_k に足したときの訓練損失勾配は

$$\nabla_w \ell_z = \frac{1}{|D_k|}(\sigma(w^\top x_z) - y_z), x_z$$

（D_k で割るのは “平均損失” に合わせるため）。影響関数の一次近似より、VB ロスの変化量は

$$\Delta L_B \approx -(\nabla_w \ell_z)^\top H^{-1} g$$

を使う。これが compute influence で返しているスコア

以後、このスコアを Interference Score（干渉スコア）と呼ぶこととする

計算量について

現時点での計算量

- ヘシアン行列 H は、モデルのパラメータ w の数だけ縦横のサイズを持つ行列であるので、例えば 28×28 ピクセルの画像を扱う場合、784×784 の行列となり、メモリとしては約 2.35MB となる

ViT の最終層の特徴次元数

- ViT-Base (ViT-B): 768 次元
- ViT-Large (ViT-L): 1024 次元
- ViT-Huge (ViT-H): 1280 次元

ViT-base で 1000 クラス分類の場合、メモリ消費量は 2.36TB となり、計算不可

対策として、LiSSA や K-FAC などの近似計算手法を使う。ViT の最終線形層への適用を想定すると、K-FAC が良さそう。

K-FAC 使用時のメモリ消費量

K-FAC: 全結合層のヘシアンは、近似的に「入力の相関行列 (A)」と「出力勾配の相関行列 (G)」のクロネッカー積（$\otimes$）に分解できることが知られている

$$H \approx A \otimes G$$

逆行列もそれぞれの逆行列の積で計算できる

$$H^{-1} \approx A^{-1} \otimes G^{-1}$$

メモリ削減効果:
例えば、入力 768 次元、出力 1000 クラスの場合：
真面目なヘシアン: $(768 \times 1000)^2 \approx$ 5900 億要素
K-FAC: $768^2 + 1000^2 \approx$ 160 万要素

これならメモリ消費量は 5.6MB くらいなはず

理論検証のための実験計画 (1/4) - 目的と設定

実験の目的

- 影響関数に基づく推定精度悪化量と、（1 枚だけ追加した場合の）実際の精度悪化量の相関
- 推定精度悪化量が高い 20 枚を追加した場合と、推定精度悪化量が低い 20 枚を追加した場合の、予測精度の比較

データセット (MNIST)

- **クラス A (追加データ)**: 手書き数字の「3」
- **クラス B (監視データ)**: 手書き数字の「8」(「3」と混同しやすいため)
- **初期データ** D_k:「3」と「8」を各 100 枚
- **クラス B 検証セット** V_B: D_k とは別の「8」を 500 枚
- **追加候補** C: D_k とは別の「3」を 50 枚
- 今回、Interference Score は「3」の追加画像が「8」の分類精度をどれだけ悪化させるかの指標となる

理論検証のための実験計画 (2/4) - ベースラインと計算

モデル

- L2 正則化ロジスティック回帰
- 目的関数が μ-強凸 ($\mu > 0$) であることが保証される。

1. ベースラインの計算

- 初期データ D_k でモデルを学習。
- 初期パラメータ $\hat{\theta}$ を保存し、ヘシアンを計算しておく
- クラス B 検証セット V_B での初期損失 $\text{Loss}_B(\hat{\theta})$ を計算（基準値）。

2. ループ検証 (候補 C の各 z' について)

A. 予測値の計算 (影響関数) (再学習なし)

理論検証のための実験計画 (3/4) - 実測値と検証

B. 実測値の計算 (Actual Loss) (再学習あり)

1. **データセット作成**:
   $D_{k+1} = D_k \cup \{z'\}$
2. **再学習の実行**:
   D_{k+1} でモデルを最初から再学習し、新パラメータ θ^*_{k+1} を得る。
3. **新損失の計算**:
   クラス B 検証セット V_B での新損失 $\text{Loss}_B(\theta^*_{k+1})$ を計算。
4. **実際の悪化量 $\Delta\text{Loss}_B(z')$ の計算**:
   $\Delta\text{Loss}_B(z') = \text{Loss}_B(\theta^*_{k+1}) - \text{Loss}_B(\hat{\theta})$

理論検証のための実験計画 (4/4) - 期待される結果

4. プロットによる検証

- 50 枚の候補 z' それぞれについて計算した「予測値」と「実測値」を散布図にプロットする。
- **X 軸**: 予測した悪化量 $\text{Interference-Score}_B(z')$
- **Y 軸**: 実際に測定した悪化量 $\Delta\text{Loss}_B(z')$

期待される結果

- **正の相関**: X 軸の値が大きい（理論的に悪影響大と予測）ほど、Y 軸の値も大きい（実際の悪影響も大）傾向が見られる。

$\lambda = 1.0 \times 10^{-1}$ の際の結果

- $\lambda = 1.0 \times 10^{-1}$ に増やした場合の結果。
- 相関は 1.00 で、実際の精度損失を予測できている。
- 相関係数の計算は numpy の *corrcoef*(*influence_arr*, *actual_loss*) で、Pearson 相関係数が 1.00 であった

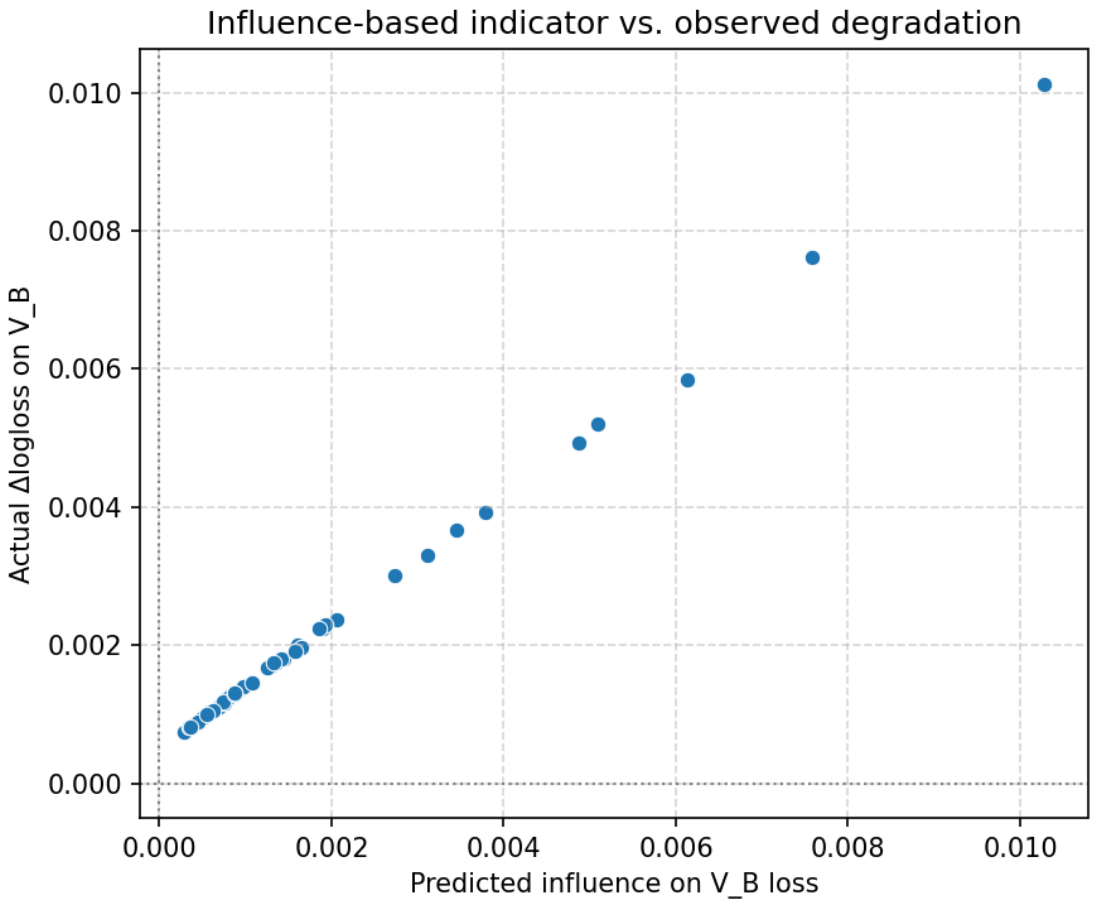

confusion matrix の結果

検証セットに、「3」と「8」の画像を 500 枚用意し、「3」と「8」の各 100 枚の画像で訓練した元のモデル (左)、低 Interference Score の「3」のサンプル 20 枚追加モデル (中央)、高干渉スコアの「3」のサンプル 20 枚追加モデル (右) での混同行列を比較した。

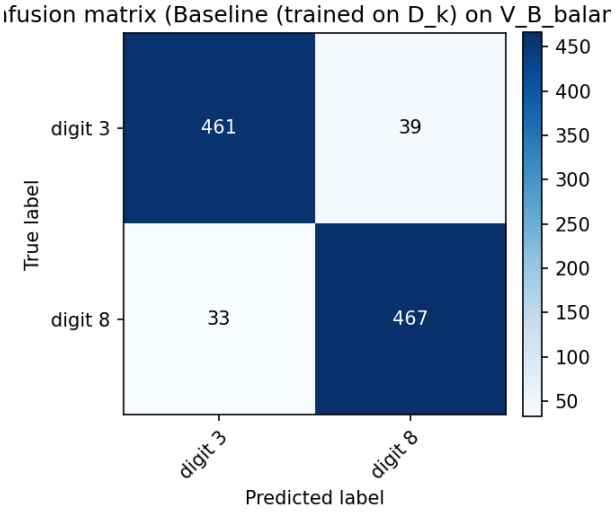

Baseline

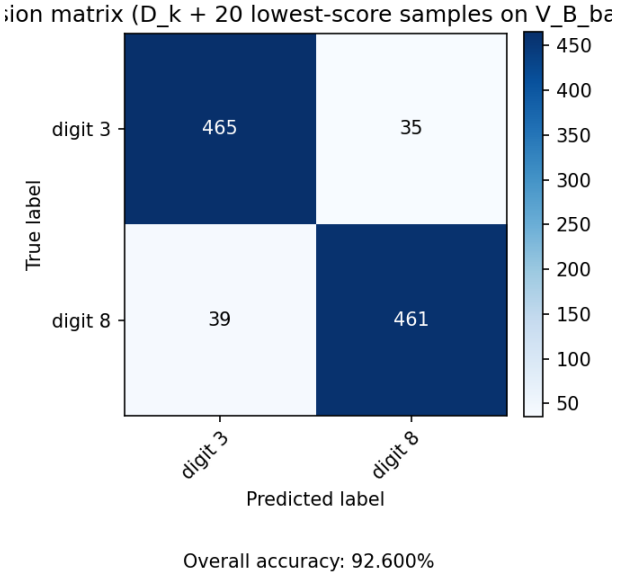

$+20$ lowest-risk

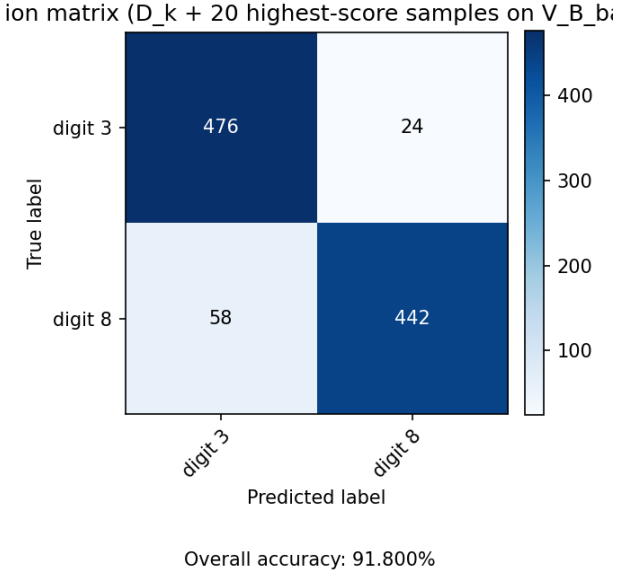

$+20$ highest-risk

- 高リスクサンプルを追加すると「8」の見逃しが 33 から 58 に増えており、理論通りの結果となった。逆に Interference Score を小さくなるように画像を生成すれば、8 の検出精度の悪化量が保証された画像となる。

画像生成への誘導スコアへの応用

目的

- 一般的に「クラス A」の画像をデータセットに追加すると、クラス A の領域が広がり、「特定クラス K」の見逃し (False Negative) が増える傾向がある。
- こういった見逃しを悪化させないような画像だけでデータセットを拡張し、モデルの識別精度を向上させたい。

方法: z を画像として、$\min_z \text{Interference-Score}_K(z)$ を解きたい

- $\text{Interference-Score}_K(z)$ は候補画像 z を追加したことによるクラス K の分類精度損失の変化の上界

生成誘導のスコア

$$z^* = \arg\min_z \left(\underbrace{\alpha_1 \cdot \mathcal{L}_{\mathrm{A}}(G(z))}_{\text{アクセル: A の検出精度を改善する}} + \underbrace{\alpha_2 \cdot \text{Interference-Score}_K(G(z))}_{\text{ブレーキ: K の検出精度を改悪しない}} \right)$$

- z: ノイズ
- $G(z)$: Diffusion モデルによる生成画像
- $\mathcal{L}_{\mathrm{A}}$: クラス A に対する分類精度を上げるための損失 (別途検討・定義)
- WUB: 画像 z を追加した時の特定クラス K の精度悪化上限
- α_1, α_2: 各項の重み

Interference Score のブレーキ項で、分類器の安全性の制約を守りながら潜在空間を探索する。

アクセル項 L_A の検討

目的

- クラス A の recall をあげる

問題

- recall $= 1 - \frac{FN}{TP+FN}$ はステップ関数であり、滑らかでない

提案

- クラス A の recall の滑らかな surrogate をあげる
- クラス A の log-loss を下げる
- $L_A^{(+)}(\theta) := \frac{1}{|V_A^{(+)}|} \sum_{i \in V_A^{(+)}} \ell(f_\theta(x_i), A)$

注

今回の実験においては、L_A 項は使用していない

Diffusion モデルの訓練

トレーニング設定

- データセット: MNIST 手書き数字画像 60,000 枚
- 画像サイズ: 28x28 ピクセル、グレースケール
- モデル: U-Net ベースの Diffusion(DDPM) モデル (VAE なし)
- エポック数: 20
- 学習率: 0.02
- ステップ数: 1000

備考

- クラス条件付きで DDPM を学習させ、0 から 9 の手書き数字画像を指定して出力できるように学習させた

生成画像の例

生成画像の例

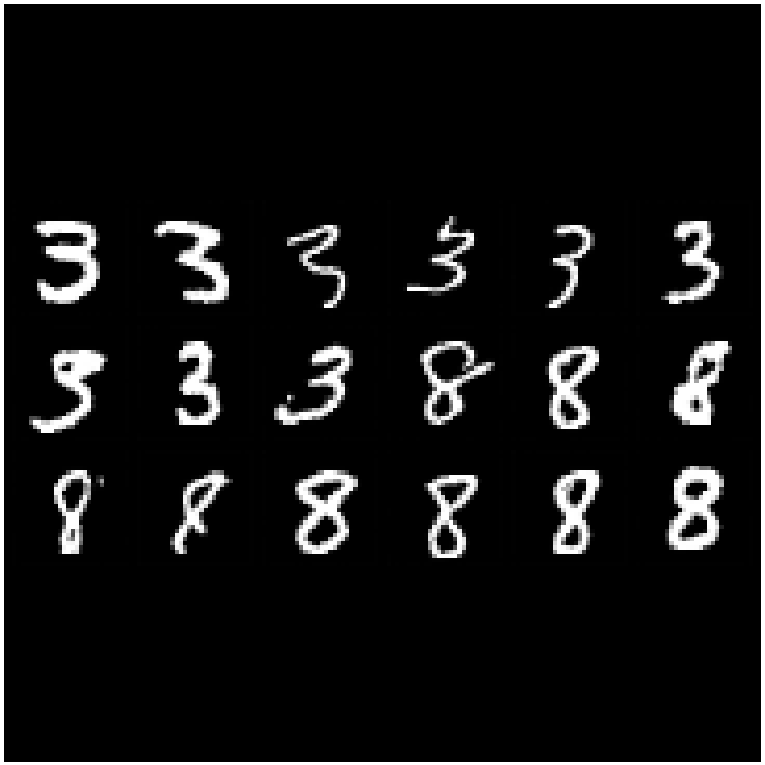

56f3: Diffusion モデルで生成された MNIST 手書き数字画像の例

生成誘導の結果例

クラス別に、誘導項なしのとき ($\alpha_1 = \alpha_2 = 0$) と、ありのとき ($\alpha_1 = 0, \alpha_2 > 0$) で生成した画像の例を示す

誘導あり / なしの生成画像 20 枚の結果比較

	誘導なし	**誘導あり**
干渉スコアの平均	-1.98e-3	-1.49e-4
干渉スコアの分散	2.84e-6	3.00e-8

表 8: Diffusion モデルで生成された画像に対する干渉スコアの比較

- 誘導ありの画像は、誘導なしに比べて干渉スコアが 10 倍以上小さい
- また、誘導なしの方は全ての画像で干渉スコアが負であったのに対し、誘導ありの方は、干渉スコアが正 (8 の検出精度を改善する) の画像もいくつかあった
- 分散は妥当？

生成画像の比較

生成画像の比較

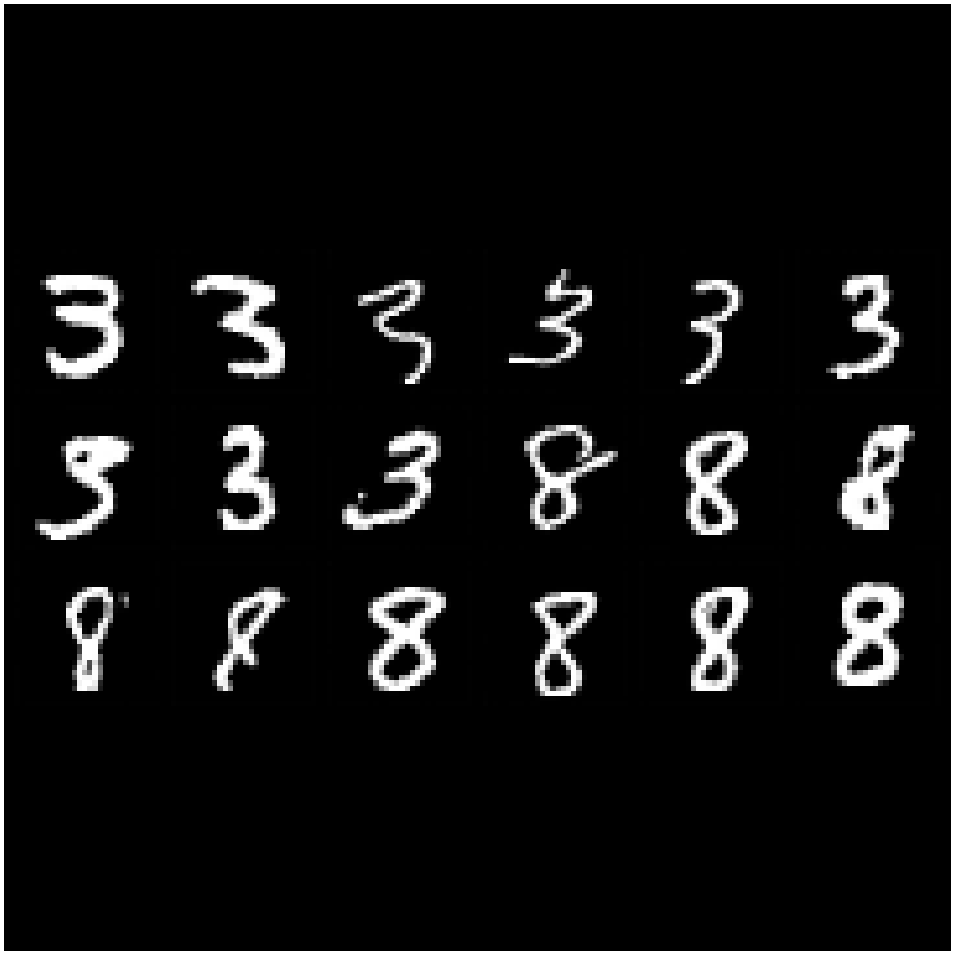

56f3: 誘導なし

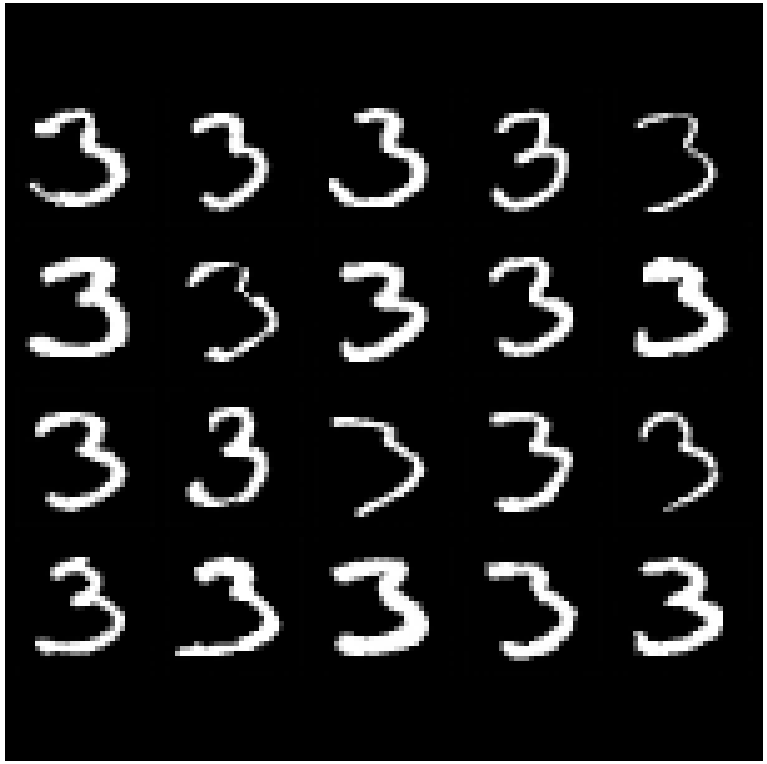

56f3: 誘導あり

再学習結果の confusion matrix の比較

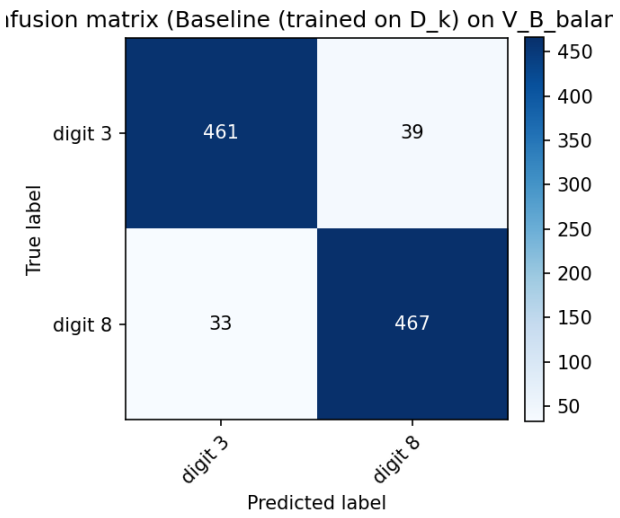

Baseline

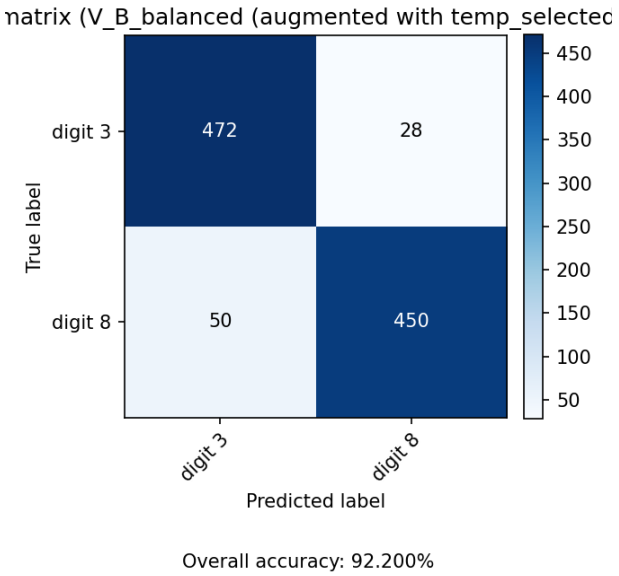

誘導なし生成画像 +20 枚

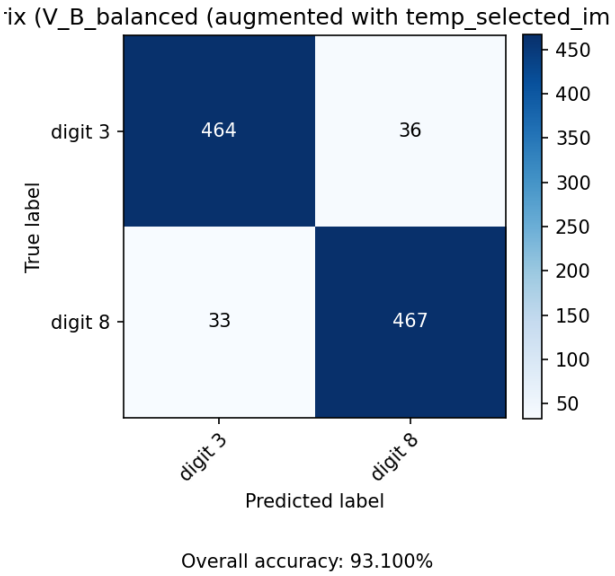

誘導あり生成画像 +20 枚

- 左側: mnist の初期の識別モデルの結果
- 真ん中: 誘導なしで生成された画像 20 枚を追加した場合の結果
- 右側: 誘導ありで生成された画像 20 枚を追加

結果に対する考察

- 誘導ありは、Baseline に比べて「8」の FN が増えずに、「3」の TP が増加
- 誘導なし生成画像を追加した場合は、「3」の TP は増えたが、「8」の FN も増えており、全体精度は悪化
- 綺麗に意図した結果が得られた

今後の課題

問題点

- 多様性とガイダンスの強さがトレードオフの関係にある
- 一枚の画像を追加したときの影響と、多数枚を一気に追加したときの影響が異なる可能性

先行研究でわかっていること

- ガイダンススケールに対して非常に敏感である
- 分類器ガイダンスを使用すると、生成画像の質が向上する代わりに多様性が損なわれるというトレードオフがある
- 多様性を確保するように、生成データ同士の類似度が閾値を超えないようにする偏差ガイダンスを併用する必要がある
- 復元過程の初期〜中期段階でセマンティックな内容が決定されるため、この段階でのみガイダンスを適用する方法がある
- 計算コストが通常に比べ 5 倍くらいになる

今後のスケジュール

今後のステップ

- 定式化の確認
- 研究テーマのポジショニング明確化
- 誘導ロジックの改善
- 多クラス設定にする
- 高解像度画像への適用を考える

展望: ViT への応用可能性

非線形モデルへの適用の課題

- ロジスティック回帰は凸最適化問題であり、強凸性やリプシッツ連続性が保証される。
- ViT のような非凸モデルに対しても、同様の理論を適用できるか？

考えられるアプローチ:

- **案 A**: ViT の特徴抽出器を固定して定数行列とみなし、最終層の線形分類器部分のみを対象とする。
- 利点と課題
  - 利点: 特徴抽出器を固定すれば、WUB の計算がそのまま適用できる。
  - 利点: ViT においては、特徴抽出器を固定して計算した影響関数の見積もりは十分実用的であることが知られている (last-layer 法)
  - 課題: 特徴抽出が不適切なら、線形層だけのチューニングは効果ない。
- **案 B**: ViT の最終層に片側 LoRA
- 利点と課題
  - 利点: 片側 LoRA は凸性であるので、理論的な計算が可能かもしれない。
  - 利点: LoRA なので特徴抽出を修正でき、ViT の Attention 機構に介入できる。
  - 課題: 理論的な計算が複雑であり、実装や計算コストが増加する
  - 課題: 両側 LoRA よりも精度が落ちる可能性がある。信頼性重視の問題設定