Influence-Guided Data Synthesis for Safe Continual Learning

Yuto Takagi

Takeuchi-Taji Lab

December 12, 2025

背景と課題：追加学習のジレンマ

現状の課題認識

運用中の AI モデルに対し、特定クラス（例：Class A）を強化するために合成データを追加学習すると、**既存の重要クラス（例：Class B）の見逃し (False Negative) が増加**してしまうことがよくある。

- **破滅的干渉**: 新しい知識が、既存の決定境界を侵食する現象
- **車載システム等の要件**:
  - 全体精度 (Accuracy) の向上だけでは不十分
  - 「以前は検出できていた歩行者が検出できなくなる」劣化は許容不可
  - 学習に追加する合成データは「安全」である必要がある

結論：再学習後にモデルを調整するのではなく、
追加するデータに“安全性基準”を設ける必要がある

本研究では、この安全性基準を Diffusion による画像生成段階へ一貫して適用し、
“Safe データ”のみを自動的に生成する仕組みを提案する

具体例：精度向上と見逃しの増加

1. 初期状態 (Before)

データセット（計 200 枚）

- Class A: 100 枚
- Class B: 100 枚

精度（バランス良）

- A 正解率: 90%
- B 正解率: 90%

全体精度: 90.0%

$\Longrightarrow$

Class A の合成画像を 100 枚追加

2. 追加学習後 (After)

データセット（計 300 枚）

- **Class A: 200 枚**
- Class B: 100 枚

精度（多数派へ過学習）

- A 正解率: $\mathbf{98}\%$ ↑
- B 正解率: $\mathbf{86}\%$ ↓ **悪化**

全体精度: 92.0% ↑

ここでの問題点

- 全体精度は $90\% \to 92\%$ と向上しているため、一見成功に見える
- しかし、モデルは「迷ったら A と答える」ようになり、**守りたかった B の見逃し (FN) は悪化**している

提案手法：Diffusion Model による「安全なデータ」の生成

コンセプト：アクセル項とブレーキ項による生成制御

アクセル (性能向上)

目的関数：Class A の性能改善
特定クラスの recall を高めるために
有用なデータを供給する力

＋

ブレーキ (干渉抑制)

干渉スコア
既存重要クラスの
損失悪化を予測し、抑制する力

- **干渉スコア (Interference Score)**:
  影響関数に基づき、「その画像を学習させた時に、保護したいクラスの検出精度にどれだけ悪影響があるか」を数値化した指標
- **生成誘導**: 生成過程で干渉スコアを最小化するように Classifier Guidance 的手法により誘導し、**「無害かつ有用なデータ」**のみを生成する

理論：影響関数による「安全性（干渉スコア）」の定量化

目的: 画像 z を追加した際、保護したいクラス B（例: 歩行者）の損失 L_B がどれだけ悪化するかを見積もりたい。

干渉スコア (Interference Score) の導出

候補画像 x_z を追加したときの、既存モデルパラメータ w への影響を一次近似で計算。

$$\Delta L_B \approx \underbrace{-(\nabla_w \ell_z)^\top}_{\text{追加データの勾配}} \cdot \underbrace{H^{-1}}_{\text{ヘシアンの逆行列}} \cdot \underbrace{g}_{\text{クラス B の勾配}}$$

- $\nabla_w \ell_z$: 追加する候補画像 z がモデルに与える勾配
- H: 既存データセットにおけるモデルのヘシアン（曲率）
- $g = \nabla_w L_B(w)$: 守りたいクラス B の損失勾配

この ΔL_B（干渉スコア）を最小化する z を生成すれば、クラス B を破壊しない。

理論：大規模モデルへの適用と計算効率

ViT 等の大規模モデルでは、パラメータ数膨大によりヘシアン H の直接計算が困難。

Last-Layer Approach と 近似計算

1. **Last-Layer Approach**:
   特徴抽出層を固定し、最終全結合層（線形層）のパラメータのみを対象に干渉を計算。
2. **K-FAC 近似**:
   ヘシアンを入力相関 A と出力勾配相関 G のクロネッカー積で近似。

$$H^{-1} \approx A^{-1} \otimes G^{-1}$$

効果:

- ViT-Base (768 次元, 1000 クラス) の場合
- 真面目な計算: 数 TB メモリ → **K-FAC 利用: 約数 MB**
- これにより、実用的な計算コストで安全性の保証が可能となる。

実験設定：MNIST における「3」と「8」の干渉

背景: 形状が似ているクラス間では干渉が起きやすい。

- **追加対象 (Class A)**: 数字の「3」
- **保護対象 (Class B)**: 数字の「8」

検証シナリオ:

1. 既存モデル（3 と 8 を各 100 枚学習済み）を用意
2. 「3」の画像を追加学習
3. 「8」の分類精度（特に見逃し）が悪化しないか検証

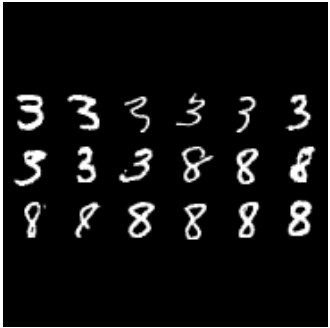

類似する「3」と「8」

検証 1：影響関数による予測精度の妥当性

問い: 導出した干渉スコアは、実際の精度悪化を正しく予測できるか？

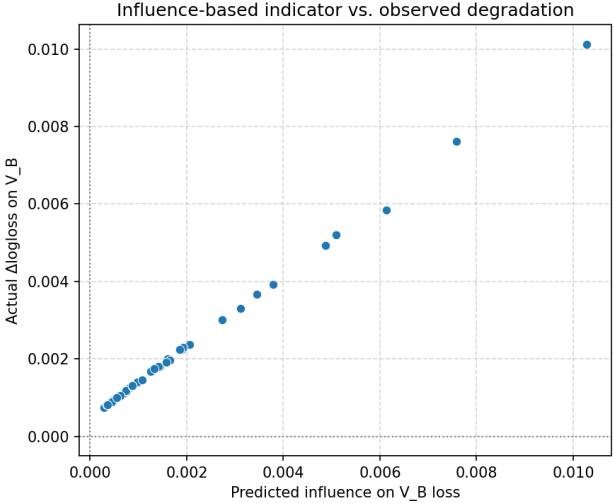

結果:

- **X 軸**: 干渉スコア（理論予測値）
- **Y 軸**: 実際の損失悪化量（再学習後の実測値）

相関係数 1.00

きれいに正の相関を示しており、
「干渉スコアを下げれば、実際の影響も抑えられる」
ことが確認された。

検証 2：生成画像データの特徴と干渉スコアの関係

問い: 高干渉スコア画像と低干渉スコア画像は、それぞれどのような特徴を持つのか？

高干渉スコア (Risky)：既存モデルを破壊するデータ

- **線が太く潰れている**
- 「8」に見間違えやすい
- これらを学習すると決定境界が歪む

低干渉スコア (Safe / Proposed)：既存モデルと共存できるデータ

- **形状が明瞭で典型的**
- 「3」と明確に判別可
- 既存の知識（8）と衝突しない

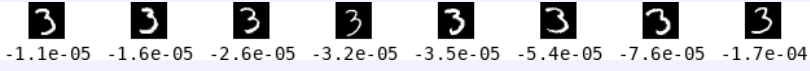

検証 3：Confusion Matrix による学習効果の可視化

問い: データセット画像のうち、高干渉スコア画像と低干渉スコア画像はどんな学習効果を及ぼすか？

Baseline (初期状態)

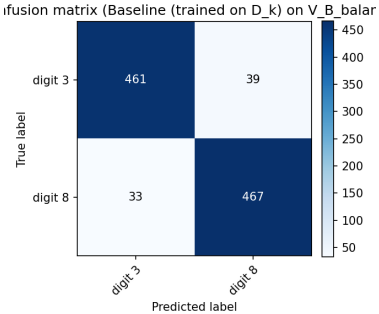

「8」の見逃し (FN): **33**

高リスク画像を追加

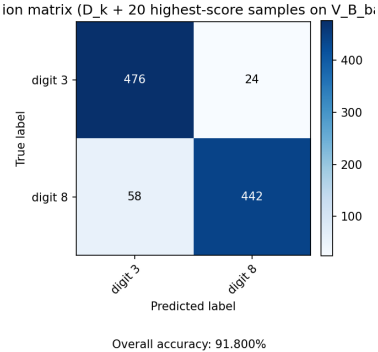

「8」の見逃し (FN): **58** ↑ 悪化

低リスク (提案) 画像を追加

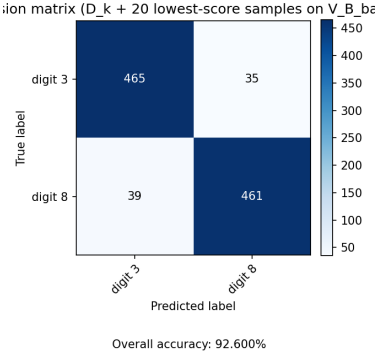

「8」の見逃し (FN): **39** → 微増

結論

実験結果: 生成誘導（Guidance）の効果

Diffusion Model の生成プロセスにおいて、干渉スコアを最小化するよう誘導（Guidance）を実施。

誘導なし (通常の生成)

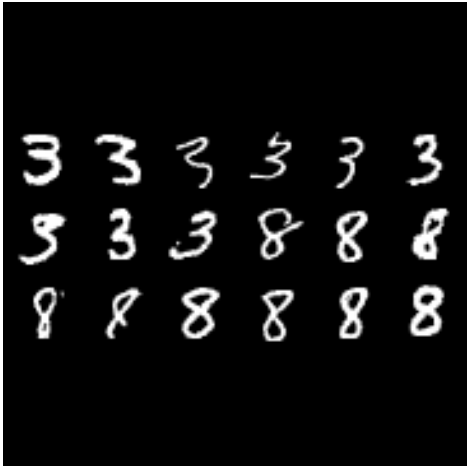

干渉スコア平均: -1.98×10^{-3}

誘導あり (Proposed)

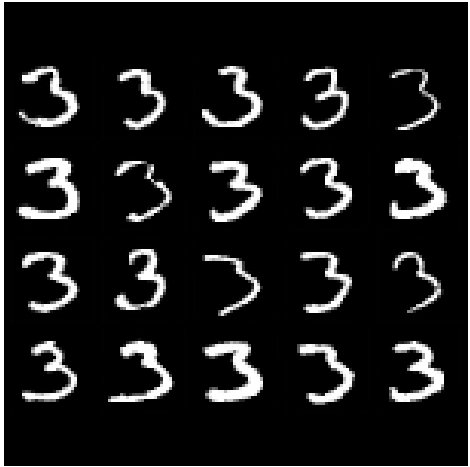

干渉スコア平均: $\mathbf{-1.49 \times 10^{-4}}$

実験結果: 生成データによる再学習の効果

干渉スコアを最小化するように誘導して生成されたデータを用いて再学習を実施

Baseline (初期状態)

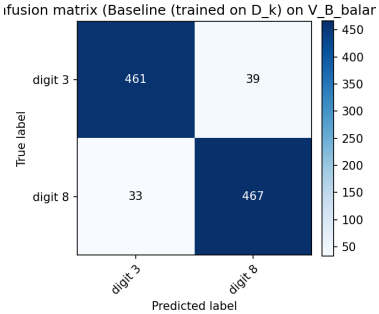

「8」の見逃し (FN): **33**

+20 ランダム生成画像

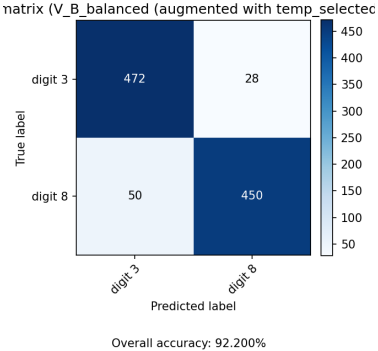

「8」の見逃し (FN): **50** ↑ 悪化

+20 誘導あり生成画像

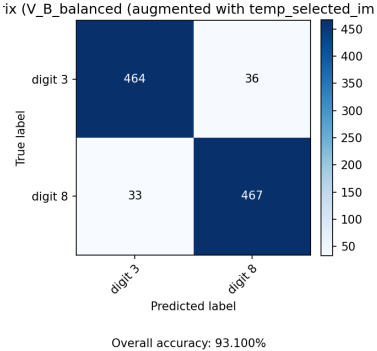

「8」の見逃し (FN): **33** → 維持
かつ全体精度↑

ViT への展開と今後の展望

Vision Transformer (ViT) への拡張

- ロジスティック回帰だけでなく、大規模モデルへの適用理論を構築中
- **Last-Layer Approach**: ViT の特徴抽出層を固定し、最終全結合層の干渉のみを計算することで、十分な精度を保ちつつ計算コストを現実的範囲に圧縮

想定ユースケース

- **コーナーケース対応**: レアな標識や障害物を追加学習したいが、基本性能（歩行者の検知など）は絶対に落とせない場面
- **データセットの品質保証 (QA)**: 数理的裏付けのあるデータ生成/選別による担保

既存機能の「安全性」を数学的に守りながら、*AI* モデルを進化させる

まとめ

- **課題**: 追加学習における「破壊的干渉（既存クラスの見逃し増加）」は、信頼性が求められる AI において致命的である。
- **提案**: 影響関数に基づいた「干渉スコア」を定義し、それをブレーキ役として Diffusion Model の生成を制御する手法を提案。
- **結果**:
  - 影響関数による理論予測と実際の影響は強く相関する。
  - 提案手法により生成された「安全なデータ」のみを追加学習することで、既存クラス（8）の性能を損なわず、ターゲットクラス（3）を強化できた。
- **今後**: ViT などの大規模モデルへの適用と、高解像度画像での実証を進める。